

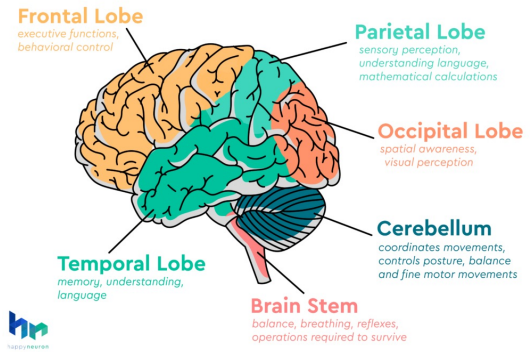
机器学习——引言

Part 1　2025/03/11　凤维杰

行动 VS 思考　类人 VS 理性

G1：类人思考

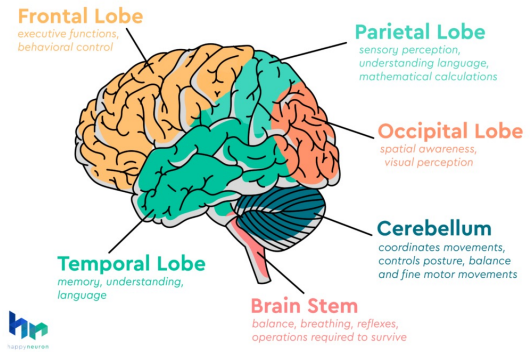
- 难点1：人类如何思考？内省、心理实验、脑成像
- 难点2：人类思维如何建模？



行动 VS 思考　类人 VS 理性

G1：类人思考

- 难点1：人类如何思考？内省、心理实验、脑成像
- 难点2：人类思维如何建模？



G2：理性思考

- 获取并用逻辑表示非形式的知识是困难的
- 原则可解决的问题 VS 实际可解决的问题

如何理解人工智能的理性思考?

已深度思考（用时 14 秒）

嗯，用户问的是如何理解人工智能的理性思考。首先，我得确定他们所说的“理性思考”具体指的是什么。可能他们是在对比人类和AI的思维方式，或者想了解AI是如何做决策的。

然后，我需要考虑用户的背景。如果他们不是技术专家，可能需要用更通俗的语言解释，避免太多术语。但如果是学生或研究人员，可能需要更深入的讨论，比如算法原理或哲学层面的问题。

接下来，应该分解问题。理性思考在人类中是逻辑推理、判断和决策的能力。但AI的理性可能更多是基于数据和模型的计算结果，缺乏人类的情感和直觉。这时候需要区分AI的理性与人类的理性有何不同。

还要考虑用户可能的潜在需求。他们可能对AI的决策过程是否可靠感兴趣，或者担心AI取代人类思考。这时候需要解释AI的局限性，比如依赖数据、无法处理未知情况等。

另外，可能需要举例子来说明，比如自动驾驶汽车在紧急情况下的决策，或者医疗诊断中的AI应用。这些例子能帮助用户更直观地理解AI如何“理性”处理问题。

还要提到AI的理性是基于预设的目标函数，比如最大化准确性或最小化损失。这与人类的多目标权衡不同，人类会考虑道德、情感等因素，而AI则严格遵循算法。

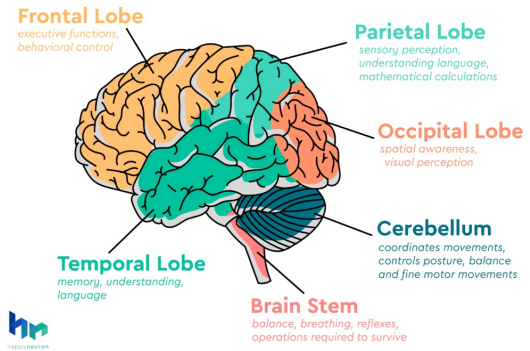
最后，应该总结AI的理性是工具性的，受限于设计和数据，而人类理性更全面。这样用户能理解两者的区别和应用场景。

人工智能的“理性思考”与人类的理性思考有本质区别，需要从技术实现、哲学边界和伦理维度综合理解：

行动 VS 思考　类人 VS 理性

G1：类人思考

- 难点1：人类如何思考？内省、心理实验、脑成像
- 难点2：人类思维如何建模？

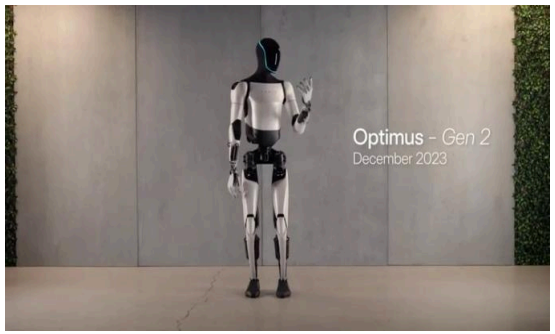


G2：理性思考

- 获取并用逻辑表示非形式的知识是困难的
- 原则可解决的问题 VS 实际可解决的问题

G3：类人行动

- 评判标准：图灵测试
- 能力需求：自然语言处理、知识表示、自动推理、机器学习、计算机视觉和机器人学

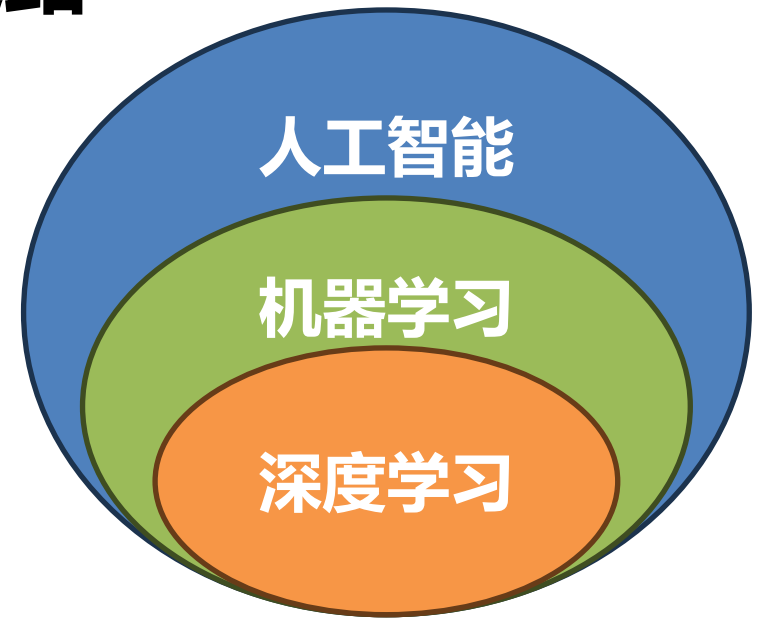


G4：理性行动

- 理性AI：为了实现最佳结果，或存在不确定性时，为了实现最佳期望结果而行动的AI

人工智能——通向智慧之路

人工智能的基本目标：开发智能机器

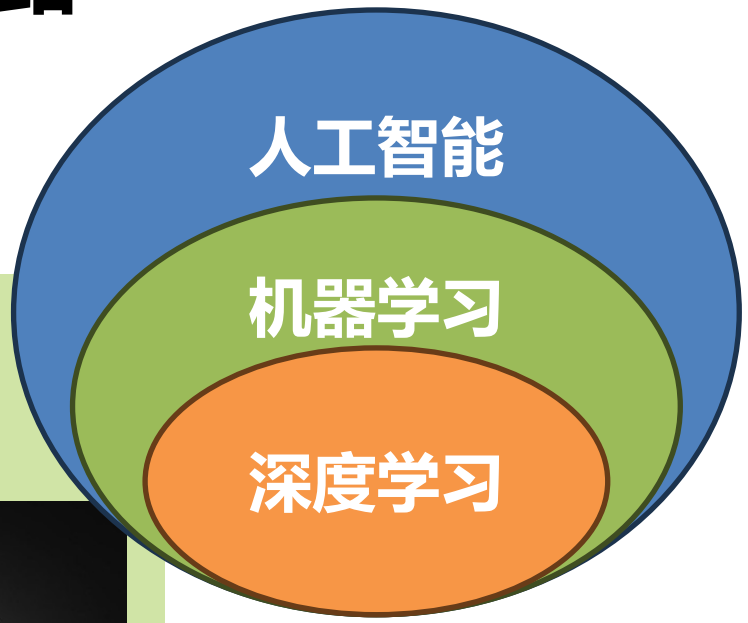


可分解为多个子目标：

- 感知
- 推理
- 控制/运动/操控
- 规划
- 交互
- 创造
- 学习

人工智能——通向智慧之路

人工智能的基本目标：开发智能机器



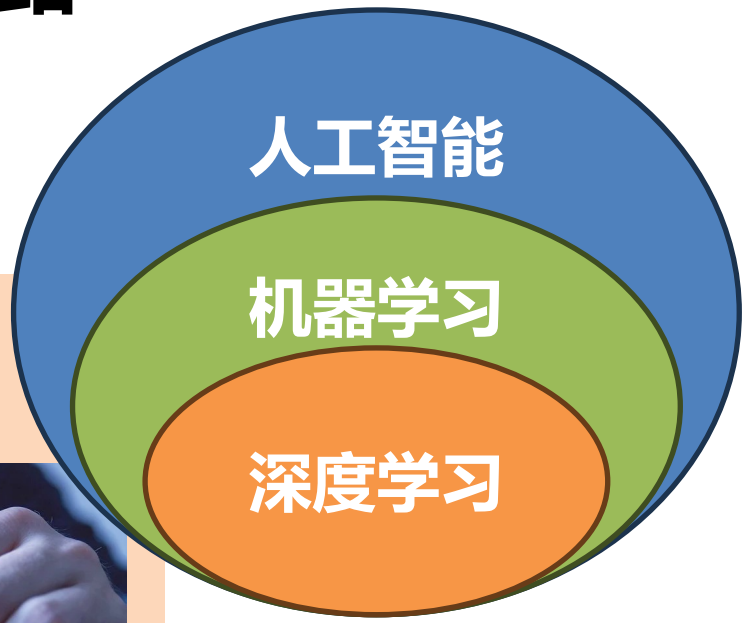
可分解为多个子目标：

- 感知
- 推理
- 控制/运动/操控
- 规划
- 交互
- 创造
- 学习



人工智能——通向智慧之路

人工智能的基本目标：开发智能机器



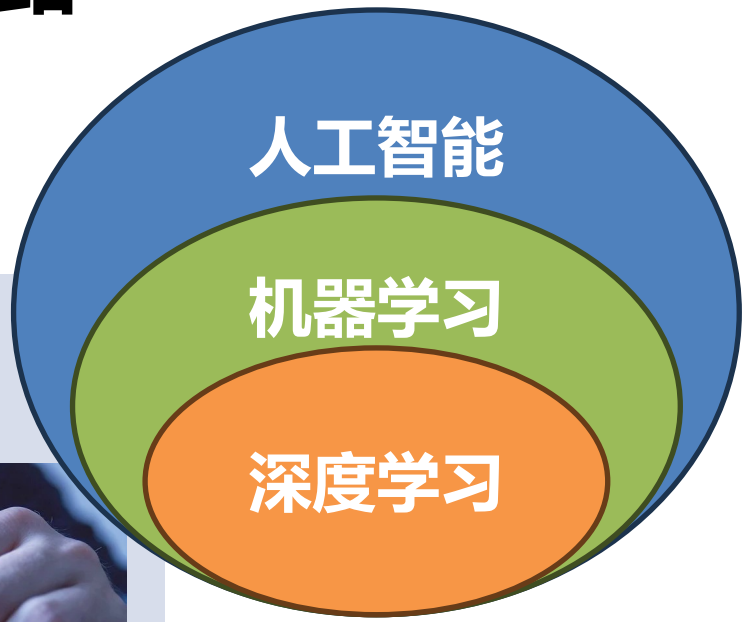
可分解为多个子目标：

- 感知
- 推理
- 控制/运动/操控
- 规划
- 交互
- 创造
- 学习



人工智能——通向智慧之路

人工智能的基本目标：开发智能机器



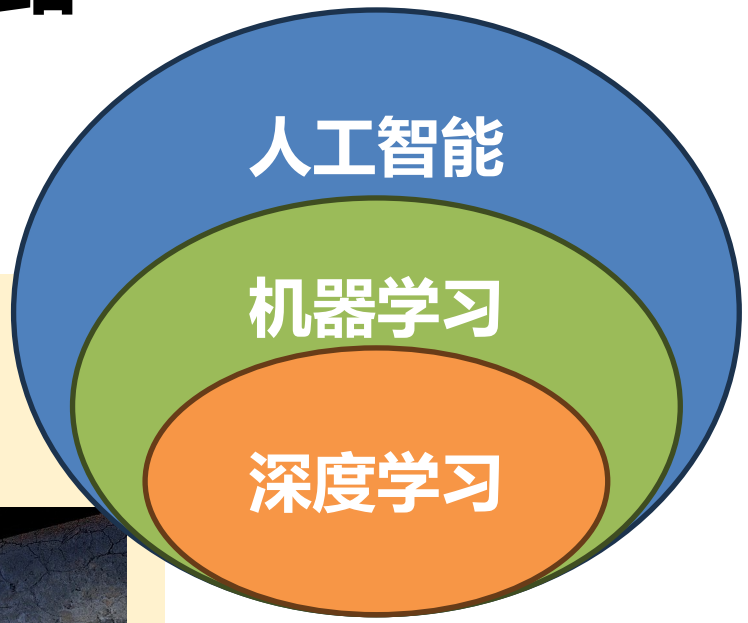
可分解为多个子目标：

- 感知
- 推理
- 控制/运动/操控
- 规划
- 交互
- 创造
- 学习



人工智能——通向智慧之路

人工智能的基本目标：开发智能机器



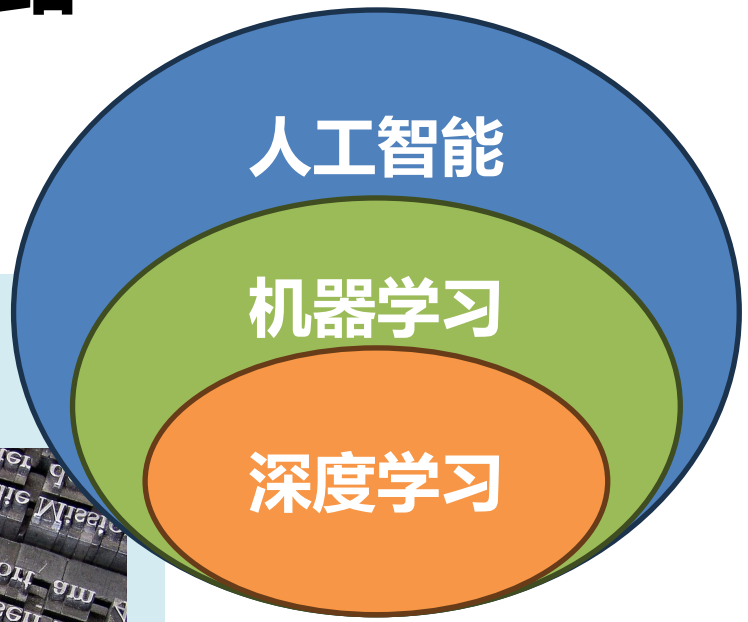
可分解为多个子目标：

- 感知
- 推理
- 控制/运动/操控
- 规划
- 交互
- 创造
- 学习



人工智能——通向智慧之路

人工智能的基本目标：开发智能机器



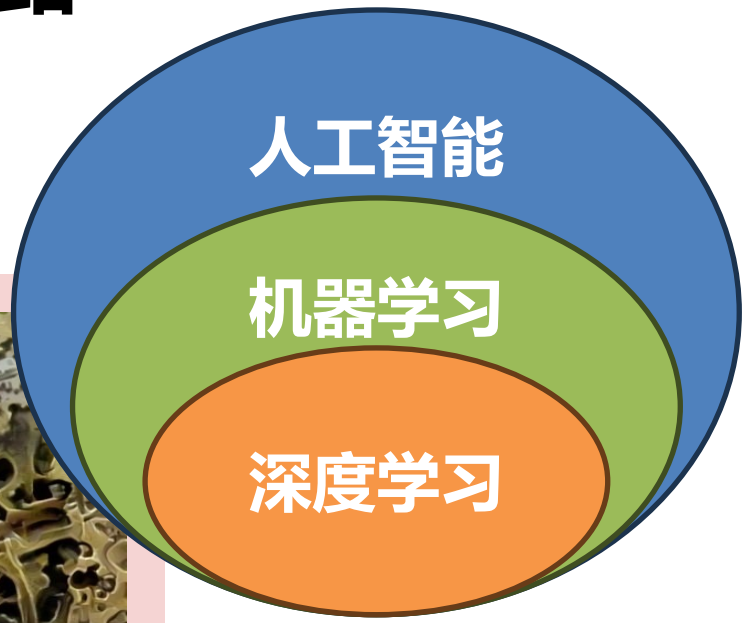
可分解为多个子目标：

- 感知
- 推理
- 控制/运动/操控
- 规划
- 交互
- 创造
- 学习



人工智能——通向智慧之路

人工智能的基本目标：开发智能机器



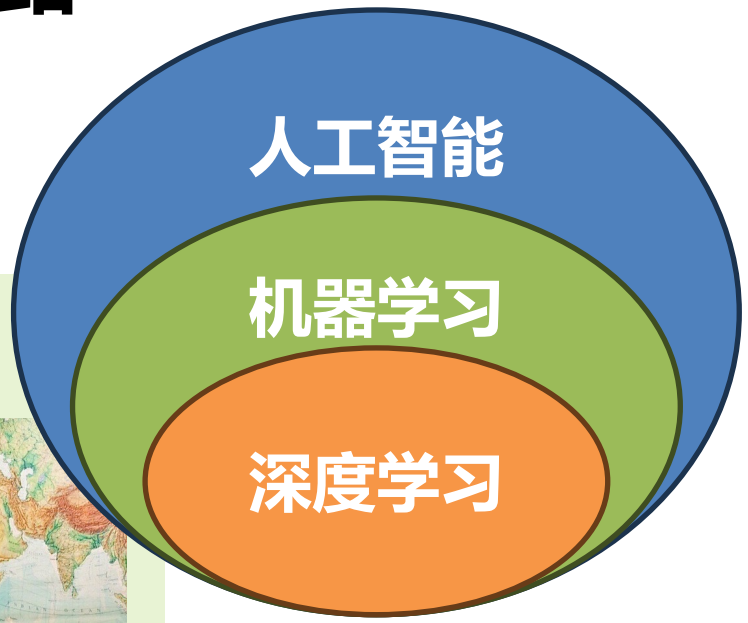
可分解为多个子目标：

- 感知
- 推理
- 控制/运动/操控
- 规划
- 交互
- 创造
- 学习



人工智能——通向智慧之路

人工智能的基本目标：开发智能机器



可分解为多个子目标：

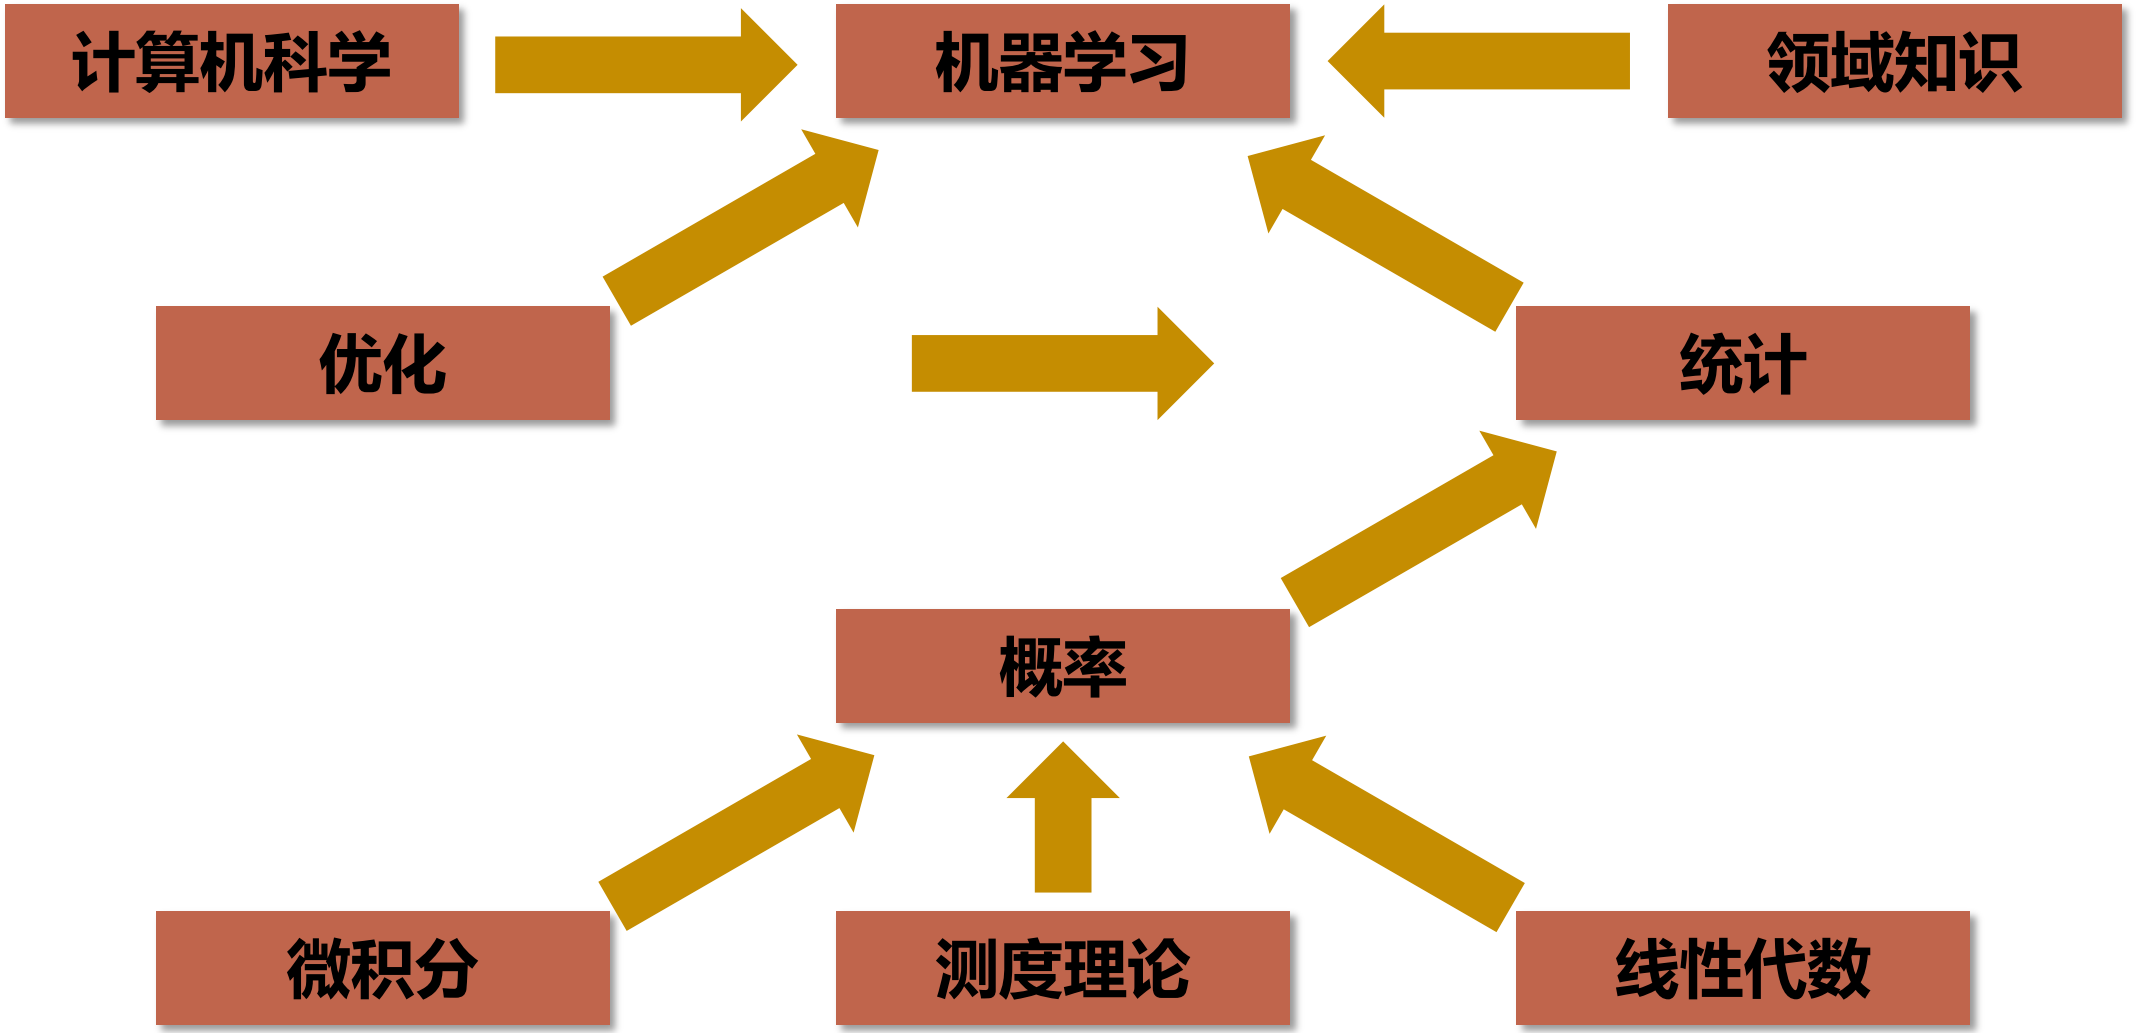
- 感知
- 推理
- 控制/运动/操控
- 规划
- 交互
- 创造
- 学习



什么是机器学习?



什么是机器学习?

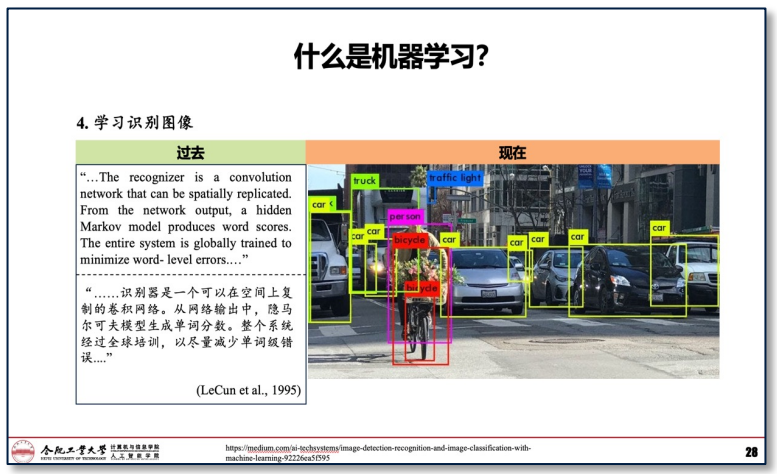


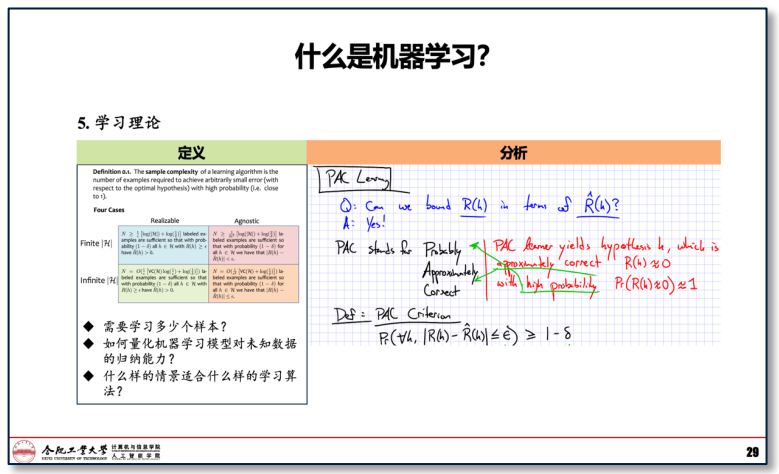
什么是机器学习?


什么是机器学习?
1. 学习语音识别
过去
现在
"…the SPHINX system (e.g. Lee 1989) learns speaker- specific strategies for recognizing the primitive sounds (phonemes) and words from the observed speech signal…neural network methods…hidden Markov models..."
"…SPHINX系统（例如，Lee 1989）通过观察到的语音信号学习特定说话者的策略，用于识别原始语音单元（音素）和词语……神经网络方法……隐马尔可夫模型……"
(Mitchell, 1997)
https://botpenguin.com/alexa-vs-siri-vs-google-assistant/
23


什么是机器学习?
2. 学习自动驾驶
过去
现在
"…the ALVINN system (Pomerleau 1989) has used its learned strategies to drive unassisted at 70 miles per hour for 90 miles on public highways among other cars…"
"…ALVINN系统（Pomerleau 1989）利用其学习到的策略，在公路上以每小时70英里的速度，穿行90英里，并且在其他车辆之间完成无人驾驶…"
(Mitchell, 1997)
https://www.robotgo.com/
24


什么是机器学习?
3. 学习游戏/推理
过去
现在
"…the world's top computer program for backgammon, TD-GAMMON (Tesauro, 1992, 1995), learned its strategy by playing over one million practice games against itself…"
"……世界顶级的双陆棋计算机程序，TD-GAMMON (Tesauro, 1992,1995)，通过与自己进行超过一百万次的练习来学习它的策略……"
(Mitchell, 1997)
ALPHAGO 00:10:29
LEE SEDOL 00:01:00
AlphaGo
27

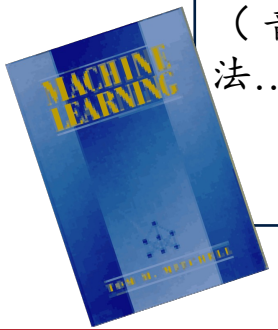

什么是机器学习?
4. 学习识别图像
过去
现在
"…The recognizer is a convolution network that can be spatially replicated. From the network output, a hidden Markov model produces word scores. The entire system is globally trained to minimize word- level errors…."
"……识别器是一个可以在空间上复制的卷积网络。从网络输出中，隐马尔可夫模型生成单词分数。整个系统经过全球培训，以尽量减少单词级错误…."
(LeCun et al., 1995)
truck
traffic light
car
person
bicycle
motorcycle
https://medium.com/ai-techsystems/image-detection-recognition-and-image-classification-with-machine-learning-92226ea5f595
28


什么是机器学习?
5. 学习理论
定义
分析
Definition o.1. The sample complexity of a learning algorithm is the number of examples required to achieve arbitrarily small error (with respect to the optimal hypothesis) with high probability (i.e. close to 1).
Four Cases
Realizable
Agnostic
Finite |H|
Infinite |H|
◆ 需要学习多少个样本？
◆ 如何量化机器学习模型对未知数据的归纳能力？
◆ 什么样的情景适合什么样的学习算法？
PAC Learning
PAC stands for Probably Approximately Correct
PAC Learner yields hypothesis h, which is approximately correct
with high probability
Def: PAC Criterion
29

什么是机器学习?

1. 学习语音识别

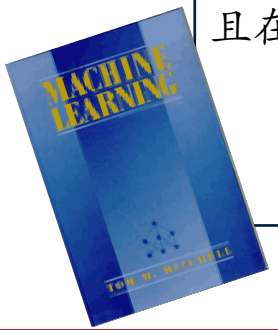
过去	现在
"…the SPHINX system (e.g. Lee 1989) learns speaker- specific strategies for recognizing the primitive sounds (phonemes) and words from the observed speech signal…neural network methods…hidden Markov models..."	
"…SPHINX系统（例如，Lee 1989）通过观察到的语音信号学习特定说话者的策略，用于识别原始语音单元（音素）和词语……神经网络方法……隐马尔可夫模型……" (Mitchell, 1997)	



什么是机器学习?

2. 学习自动驾驶

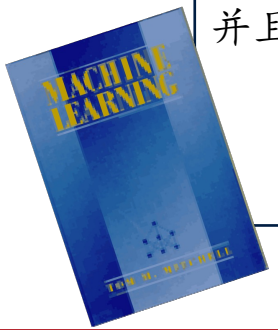
过去	现在
"…the ALVINN system (Pomerleau 1989) has used its learned strategies to drive unassisted at 70 miles per hour for 90 miles on public highways among other cars…"	
"…ALVINN系统（Pomerleau 1989）利用其学习到的策略，在公路上以每小时70英里的速度，穿行90英里，并且在其他车辆之间完成无人驾驶…" (Mitchell, 1997)	



什么是机器学习?

2. 学习自动驾驶

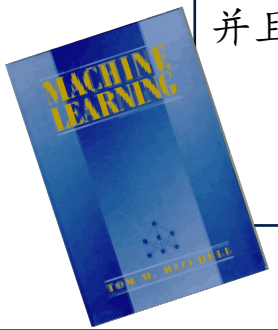
过去	现在
"…the ALVINN system (Pomerleau 1989) has used its learned strategies to drive unassisted at 70 miles per hour for 90 miles on public highways among other cars…"	 
"…ALVINN系统（Pomerleau 1989）已经利用其学习到的策略，在公路上以每小时70英里的速度，穿行90英里，并且在其他车辆之间完成无人驾驶…" (Mitchell, 1997)	 



什么是机器学习?

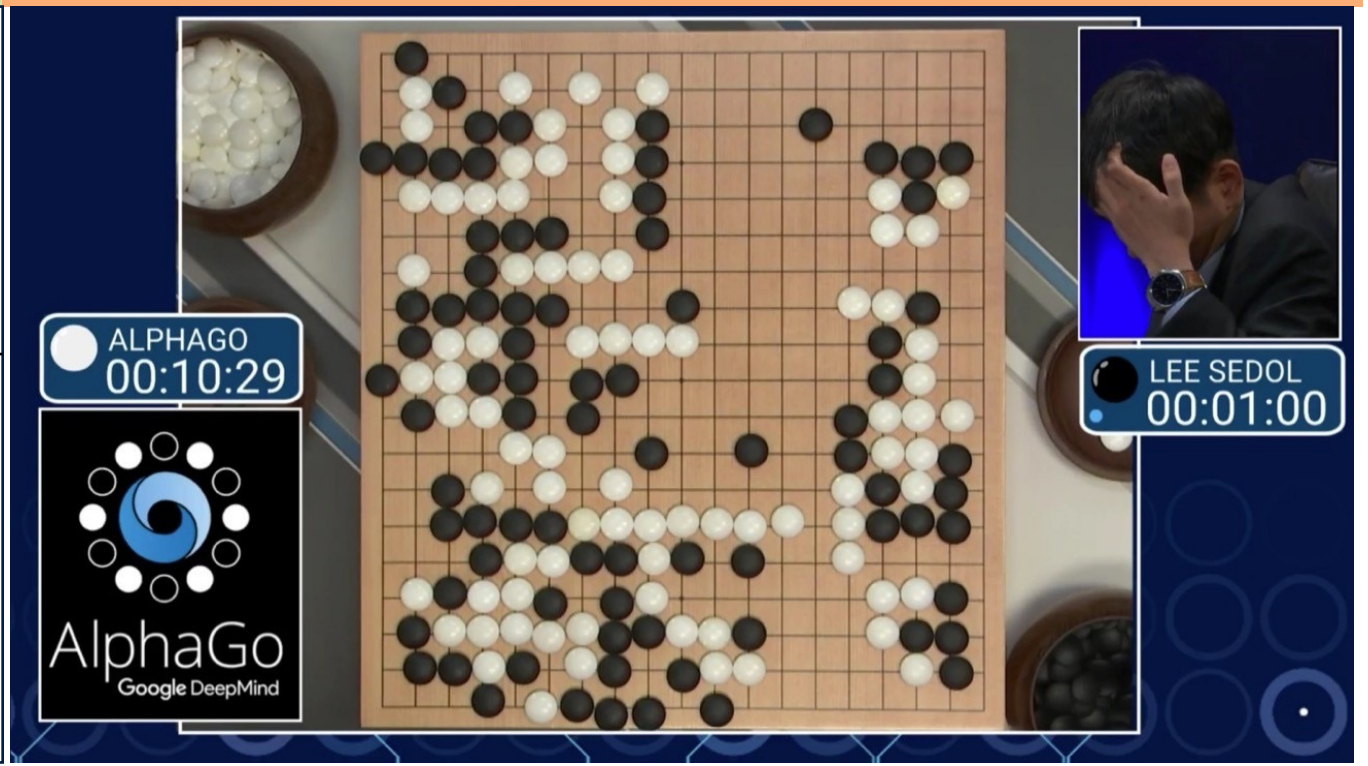
2. 学习自动驾驶

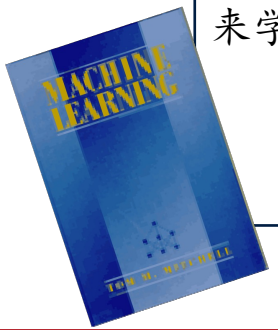
过去	现在
"…the ALVINN system (Pomerleau 1989) has used its learned strategies to drive unassisted at 70 miles per hour for 90 miles on public highways among other cars…"	
"…ALVINN系统（Pomerleau 1989）已经利用其学习到的策略，在公路上以每小时70英里的速度，穿行90英里，并且在其他车辆之间完成无人驾驶…" (Mitchell, 1997)	



什么是机器学习?

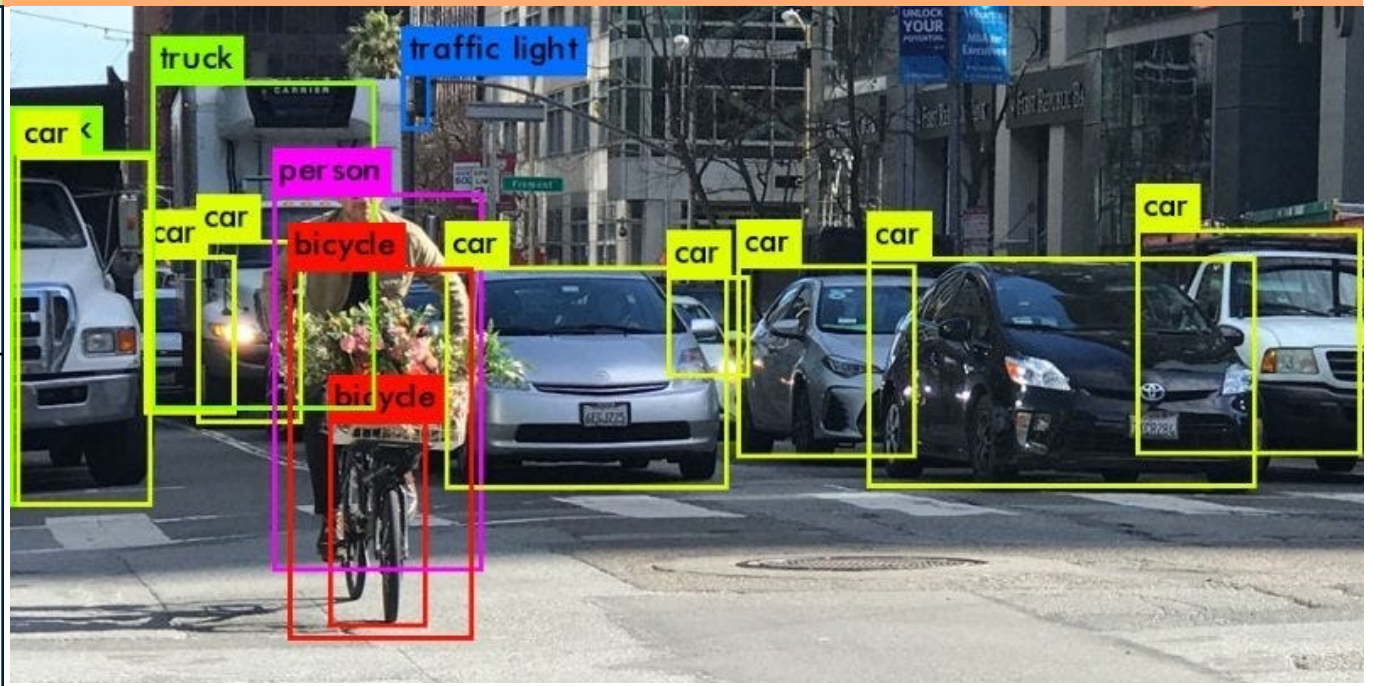
3. 学习游戏/推理

过去	现在
"…the world's top computer program for backgammon, TD-GAMMON (Tesauro, 1992, 1995), learned its strategy by playing over one million practice games against itself…"	
"……世界顶级的双陆棋计算机程序，TD-GAMMON (Tesauro, 1992,1995)，通过与自己进行超过一百万次的练习来学习它的策略……" (Mitchell, 1997)	



什么是机器学习?

4. 学习识别图像

过去	现在
"…The recognizer is a convolution network that can be spatially replicated. From the network output, a hidden Markov model produces word scores. The entire system is globally trained to minimize word- level errors…."	
"……识别器是一个可以在空间上复制的卷积网络。从网络输出中，隐马尔可夫模型生成单词分数。整个系统经过全球培训，以尽量减少单词级错误...."	
(LeCun et al., 1995)	

https://medium.com/ai-techsystems/image-detection-recognition-and-image-classification-with-machine-learning-92226ea5f595

什么是机器学习?

5. 学习理论

定义

Definition 0.1. The **sample complexity** of a learning algorithm is the number of examples required to achieve arbitrarily small error (with respect to the optimal hypothesis) with high probability (i.e. close to 1).

Four Cases

	Realizable	Agnostic
Finite $\|\mathcal{H}\|$	$N \geq \frac{1}{\epsilon}\left[\log(\|\mathcal{H}\|)+\log(\frac{1}{\delta})\right]$ labeled examples are sufficient so that with probability $(1-\delta)$ all $h \in \mathcal{H}$ with $R(h) \geq \epsilon$ have $\hat{R}(h) > 0$.	$N \geq \frac{1}{2\epsilon^2}\left[\log(\|\mathcal{H}\|)+\log(\frac{2}{\delta})\right]$ labeled examples are sufficient so that with probability $(1-\delta)$ for all $h \in \mathcal{H}$ we have that $\|R(h) - \hat{R}(h)\| < \epsilon$.
Infinite $\|\mathcal{H}\|$	$N = O(\frac{1}{\epsilon}\left[\text{VC}(\mathcal{H})\log(\frac{1}{\epsilon})+\log(\frac{1}{\delta})\right])$ labeled examples are sufficient so that with probability $(1-\delta)$ all $h \in \mathcal{H}$ with $R(h) \geq \epsilon$ have $\hat{R}(h) > 0$.	$N = O(\frac{1}{\epsilon^2}\left[\text{VC}(\mathcal{H})+\log(\frac{1}{\delta})\right])$ labeled examples are sufficient so that with probability $(1-\delta)$ for all $h \in \mathcal{H}$ we have that $\|R(h) - \hat{R}(h)\| \leq \epsilon$.

- 需要学习多少个样本?
- 如何量化机器学习模型对未知数据的归纳能力?
- 什么样的情景适合什么样的学习算法?

分析

PAC Learning

Q: Can we bound $R(h)$ in terms of $\hat{R}(h)$?

A: Yes!

PAC stands for Probably Approximately Correct

PAC learner yields hypothesis h, which is approximately correct $R(h) \approx 0$ with high probability $Pr(R(h) \approx 0) \approx 1$

Def: PAC Criterion

$$Pr(\forall h, |R(h) - \hat{R}(h)| \leq \epsilon) \geq 1 - \delta$$

什么是机器学习?

定义 [编辑]

机器学习有下面几种定义：

- 机器学习是一门人工智能的科学，该领域的主要研究对象是人工智能，特别是如何在经验学习中改善具体算法的性能。
- 机器学习是对能通过经验自动改进的计算机算法的研究。
- 机器学习是用数据或以往的经验，以此优化计算机程序的性能标准。

另外，计算机科学家汤姆·米切尔在其著作的Machine Learning一书中定义的机器学习为[1]：

> A computer program is said to learn from experience E with respect to some class of tasks T and performance measure P, if its performance at tasks in T, as measured by P, improves with experience E.
>
> ——Tom Mitchell，Machine Learning

- 1956 年，Arthur Samuel 在达特茅斯会议上定义了 “机器学习”一词，定义为在没有明确设置的情况下，使计算机具有学习能力的研究领域。

- 1997 年，Tom Mitchell 提供了一个更现代的定义：若一个程序通过利用经验E在 任务T中获得了性能改善，则我们就说关于任务T和性能测量P，该程序对经验E进行了学习

https://en.wikipedia.org/wiki/Machine_learning

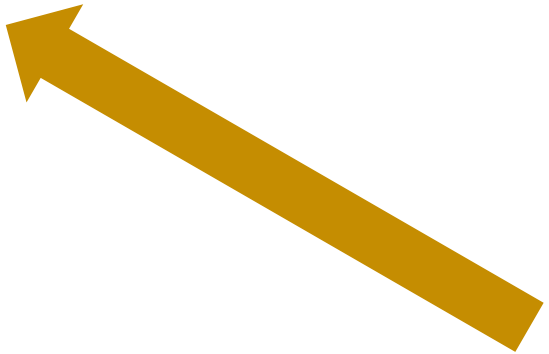
什么是机器学习?

三个关键组件 <T, P, E>:

1. 任务T:

2. 性能度量P:

3. 经验E:



- 1956 年，Arthur Samuel 在达特茅斯会议上定义了“机器学习”一词，定义为在没有明确设置的情况下，使计算机具有学习能力的研究领域。

- 1997 年，Tom Mitchell 提供了一个更现代的定义：若一个程序通过利用经验E在 任务T中获得了性能改善，则我们就说关于任务T和性能测量P，该程序对经验E进行了学习

什么是机器学习?

三个关键组件 <T, P, E>:

1. 任务T:
   下围棋
2. 性能度量P:
   比赛中击败对手的概率
3. 经验E:
   和自己进行对弈

围棋学习问题



- 1956 年，Arthur Samuel 在达特茅斯会议上定义了“机器学习”一词，定义为在没有明确设置的情况下，使计算机具有学习能力的研究领域。

- 1997 年，Tom Mitchell 提供了一个更现代的定义：若一个程序通过利用经验E在 任务T中获得了性能改善，则我们就说关于任务T和性能测量P，该程序对经验E进行了学习

https://m.mp.oeeee.com/a/BAAFRD000020230615809485.html

什么是机器学习?

三个关键组件 <T, P, E>:

1. 任务T:
   通过传感器在道路上行驶
2. 性能度量P:
   平均无差错行驶里程
3. 经验E:
   人类驾驶时录制的一系列图像和指令

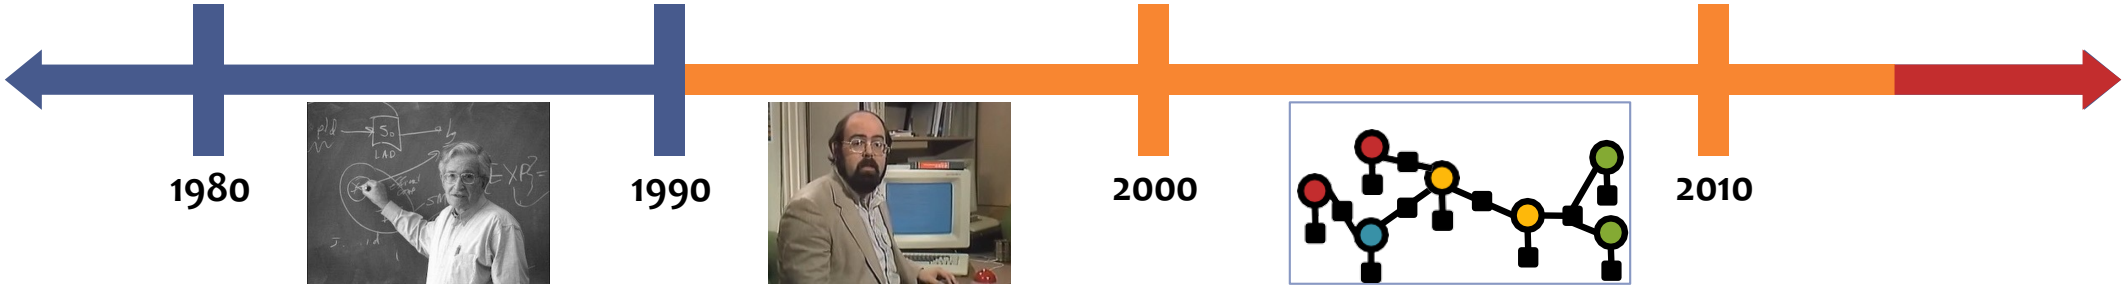
自动驾驶学习问题



- 1956 年，Arthur Samuel 在达特茅斯会议上定义了“机器学习”一词，定义为在没有明确设置的情况下，使计算机具有学习能力的研究领域。

- 1997 年，Tom Mitchell 提供了一个更现代的定义：若一个程序通过利用经验E在 任务T中获得了性能改善，则我们就说关于任务T和性能测量P，该程序对经验E进行了学习

学习专家知识



Solution #1: 专家系统

- 机器学习早期，基于规则的系统：
  1. 召集一群语言学家
  2. 专家思考母语结构，并设计程序运行规则

火车站在哪个方向？

```
If: "X在哪个方向"
Then: directions(here, nearest(X))
```

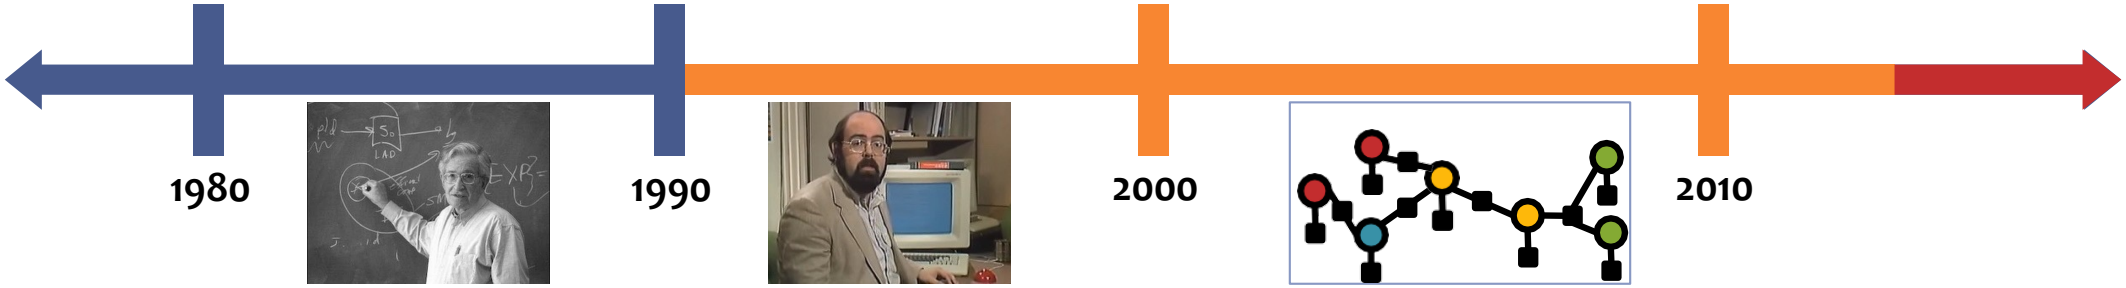
如何去火车站？

```
If: "如何去X"
Then: directions(here, nearest(X))
```

最近的火车站在哪？

```
If: "最近的X在哪"
Then: directions(here, nearest(X))
```

学习专家知识



Solution #1: 专家系统

- 机器学习早期，基于规则的系统：
  1. 召集一群语言学家
  2. 专家思考母语结构，并设计程序运行规则

我需要去火车站

If: "我需要去X"
Then: directions(here, nearest(X))

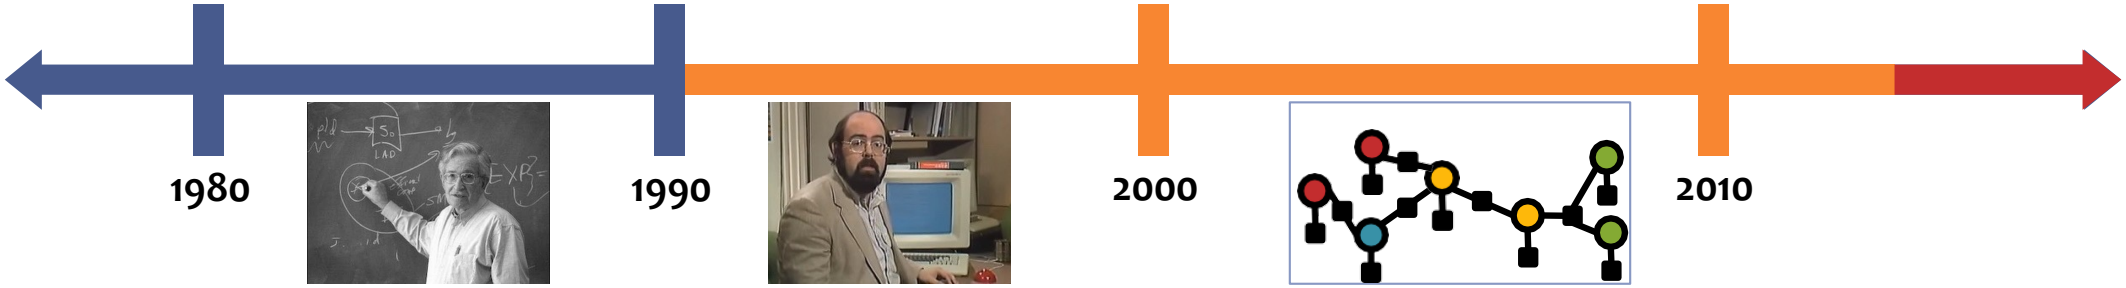
导航火车站

If: "导航X"
Then: directions(here, nearest(X))

附近有火车站吗?

If: "附近有X吗"
Then: directions(here, nearest(X))

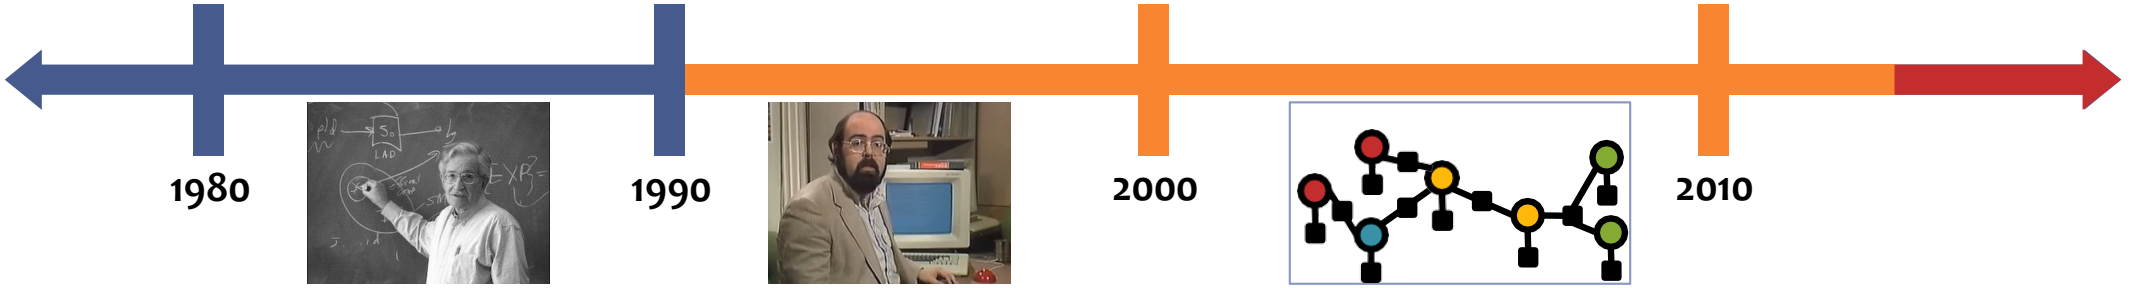
学习专家知识



Solution #2: 标注数据并学习

- 专家：
  - 非常擅长回答关于具体案例的问题
  - 不擅长解释如何求解该问题
- 1990s：模仿专家在具体案例中所做的，并在其他案例上进行实践

学习专家知识



Solution #2: 标注数据并学习

1. 收集语句 $\{x^{(1)}, \ldots, x^{(n)}\}$
2. 专家对每个语句进行标注 $\{y^{(1)}, \ldots, y^{(n)}\}$

$x^{(1)}$：我需要去火车站
$y^{(1)}$：directions(here, nearest(火车站))

$x^{(2)}$：最近的火车站在哪
$y^{(2)}$：map(nearest(火车站))

$x^{(3)}$：通知同学们明天考试
$y^{(3)}$：txtmsg(students, "Exam tomorrow")

$x^{(4)}$：定一个七点的闹钟
$y^{(4)}$：setalarm(7:00 AM)

问题描述

输入：

- 由n个样本组成的（训练）数据集

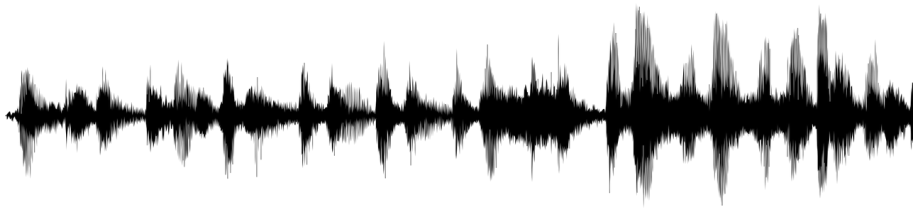
目标：

- 预测输入的类别

Ex：

- 股票预测
- 语音合成
- 天气预测
- ……







问题描述

输入：

- 由n个样本组成的（训练）数据集
- 对于每个样本$i \in \{1, \ldots, n\}$

问题描述

输入：

- 由n个样本组成的（训练）数据集
- 对于每个样本$i \in \{1, \ldots, n\}$
  - 特征向量$x^{(i)} = \left(x_1^{(i)}, \cdots, x_d^{(i)}\right)^T \in \mathbb{R}^d$

问题描述

输入：

- 由n个样本组成的（训练）数据集
- 对于每个样本$i \in \{1, \ldots, n\}$
  - 特征向量$x^{(i)} = \left(x_1^{(i)}, \cdots, x_d^{(i)}\right)^T \in \mathbb{R}^d$

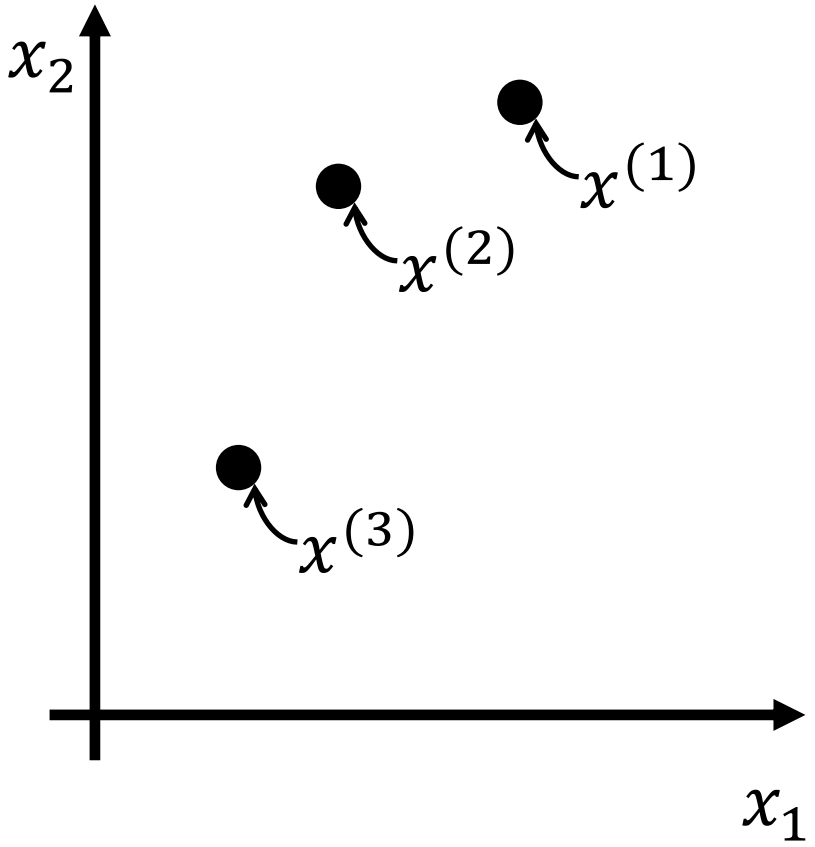
$$x^{(i)} = (\text{早八？ 人数？ 拖堂？ } \cdots)^{\mathrm{T}} = \left(x_1^{(i)}, x_2^{(i)}, \cdots\right)^{\mathrm{T}}$$

问题描述

输入：

- 由n个样本组成的（训练）数据集
- 对于每个样本$i \in \{1, \ldots, n\}$
  - 特征向量$x^{(i)} = \left(x_1^{(i)}, \cdots, x_d^{(i)}\right)^T \in \mathbb{R}^d$

$$x^{(i)} = (\text{早八，人数})^{\mathrm{T}} = \left(x_1^{(i)}, x_2^{(i)}\right)^{\mathrm{T}}$$
$$x^{(1)} = (\text{早八，人数})^{\mathrm{T}} = (0.8, 90)^{\mathrm{T}}$$
$$x^{(2)} = (\text{早八，人数})^{\mathrm{T}} = (0.7, 85)^{\mathrm{T}}$$
$$x^{(3)} = (\text{早八，人数})^{\mathrm{T}} = (0.65, 31)^{\mathrm{T}}$$



问题描述

输入：

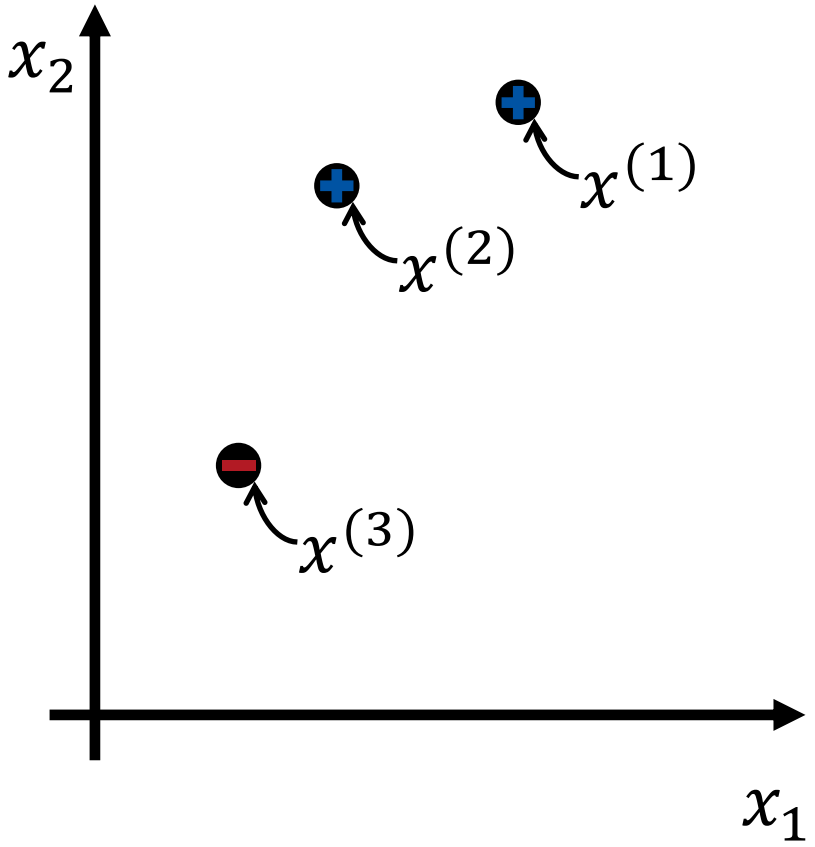
- 由n个样本组成的（训练）数据集
- 对于每个样本$i \in \{1, \ldots, n\}$
  - 特征向量$x^{(i)} = \left(x_1^{(i)}, \cdots, x_d^{(i)}\right)^T \in \mathbb{R}^d$
  - 标签$y^{(i)} \in \{-1, +1\}$

$$x^{(i)} = (\text{早八，人数})^{\mathrm{T}} = \left(x_1^{(i)}, x_2^{(i)}\right)^{\mathrm{T}}$$

$$x^{(1)} = (\text{早八，人数})^{\mathrm{T}} = (0.8, 90)^{\mathrm{T}} \quad y^{(1)} = \text{点名} = +1$$

$$x^{(2)} = (\text{早八，人数})^{\mathrm{T}} = (0.7, 85)^{\mathrm{T}} \quad y^{(2)} = \text{点名} = +1$$

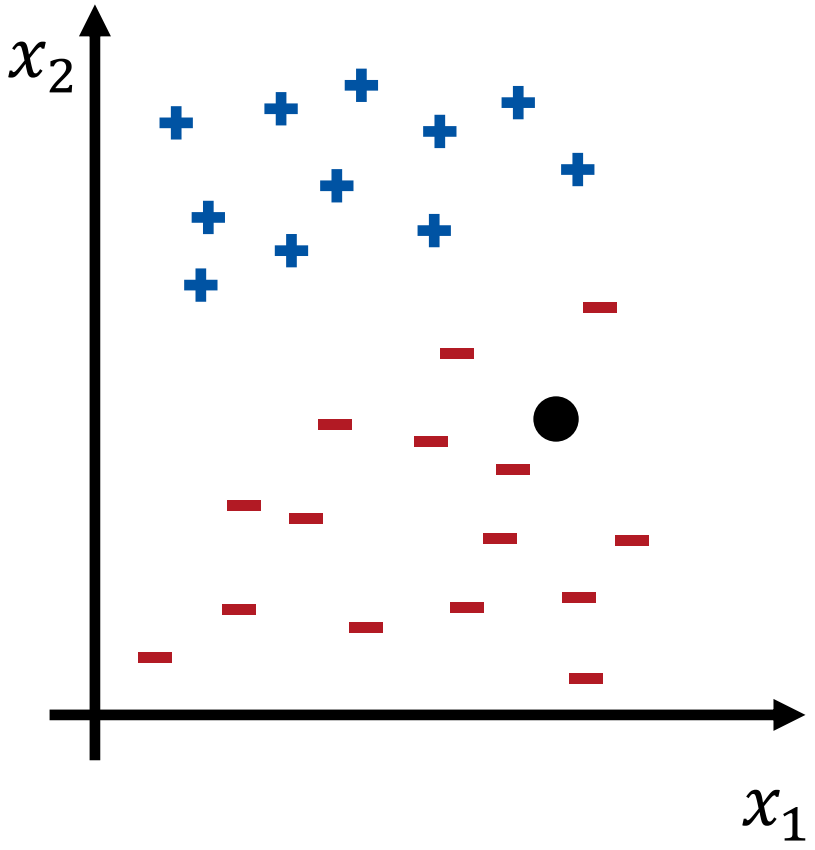
$$x^{(3)} = (\text{早八，人数})^{\mathrm{T}} = (0.65, 31)^{\mathrm{T}} \quad y^{(3)} = \text{不点} = -1$$



问题描述

输入：

- 由n个样本组成的（训练）数据集
- 对于每个样本$i \in \{1, \ldots, n\}$
  - 特征向量$x^{(i)} = \left(x_1^{(i)}, \cdots, x_d^{(i)}\right)^T \in \mathbb{R}^d$
  - 标签$y^{(i)} \in \{-1, +1\}$
- 训练数据$\mathcal{D}_n = \left\{\left(x^{(1)}, y^{(1)}\right), \cdots, \left(x^{(n)}, y^{(n)}\right)\right\}$

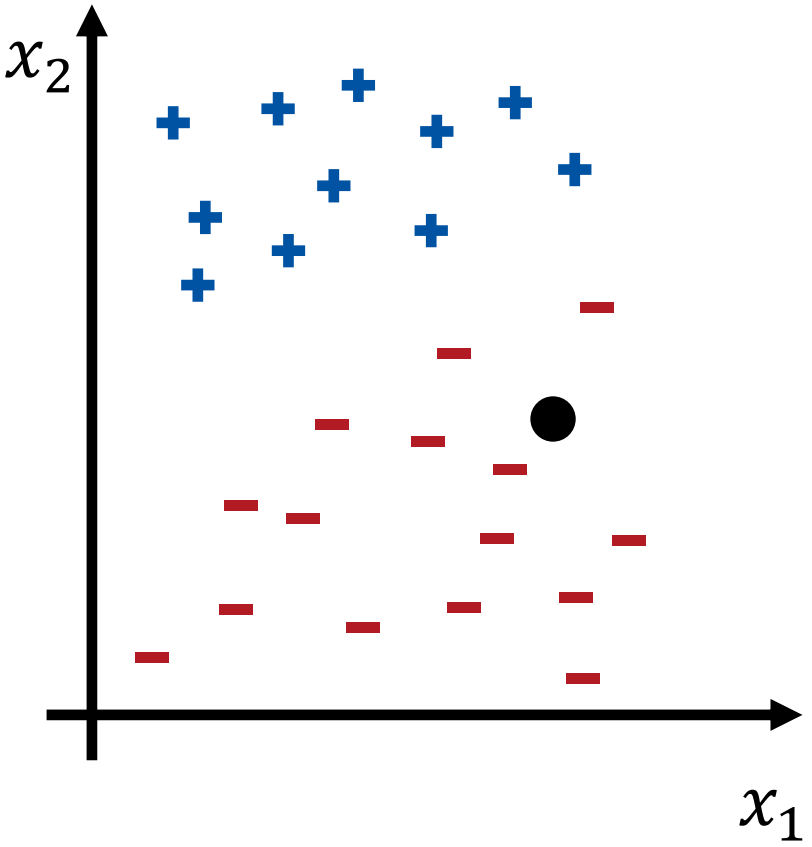


目标： 能够精准地预测新样本的标签

问题描述

输入：

- 由n个样本组成的（训练）数据集
- 对于每个样本$i \in \{1, \ldots, n\}$
  - 特征向量$x^{(i)} = \left(x_1^{(i)}, \cdots, x_d^{(i)}\right)^T \in \mathbb{R}^d$
  - 标签$y^{(i)} \in \{-1, +1\}$
- 训练数据$\mathcal{D}_n = \left\{\left(x^{(1)}, y^{(1)}\right), \cdots, \left(x^{(n)}, y^{(n)}\right)\right\}$



目标： 能够精准地预测新样本的标签

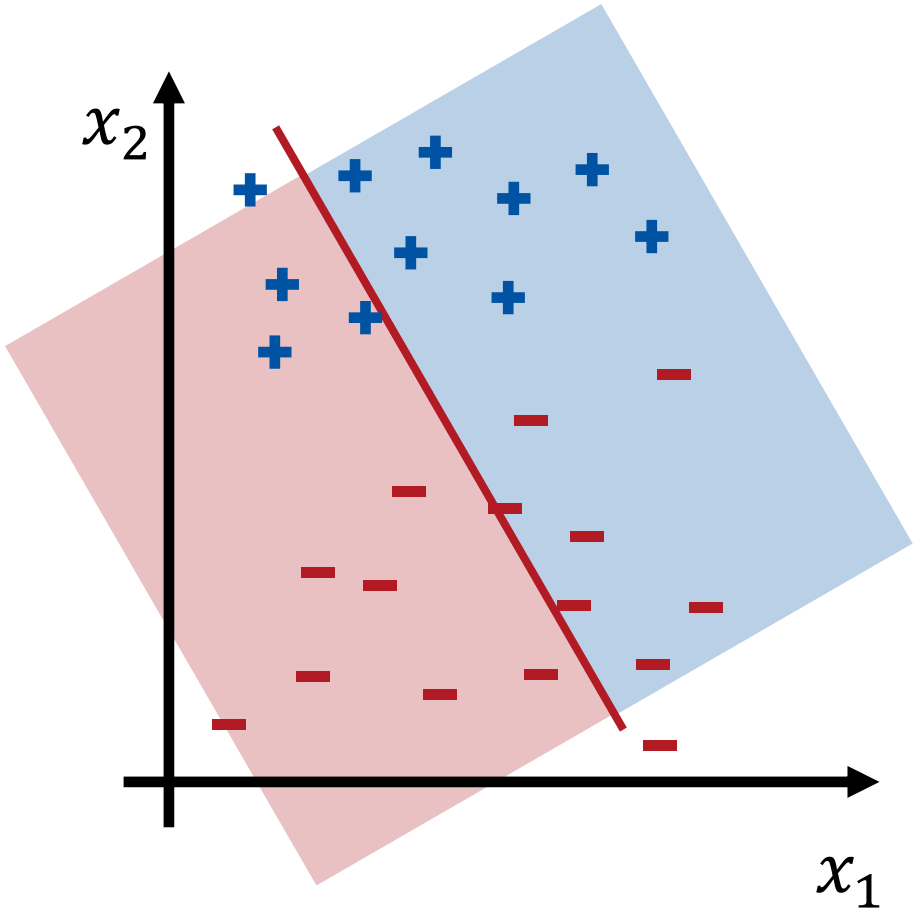
- 如何预测？ 假设$h: \mathbb{R}^d \to \{-1, +1\}$ $x \rightarrow h \rightarrow y$

Ex h: 对于任意$x, h(x) = +1$

这是一个好的假设吗？

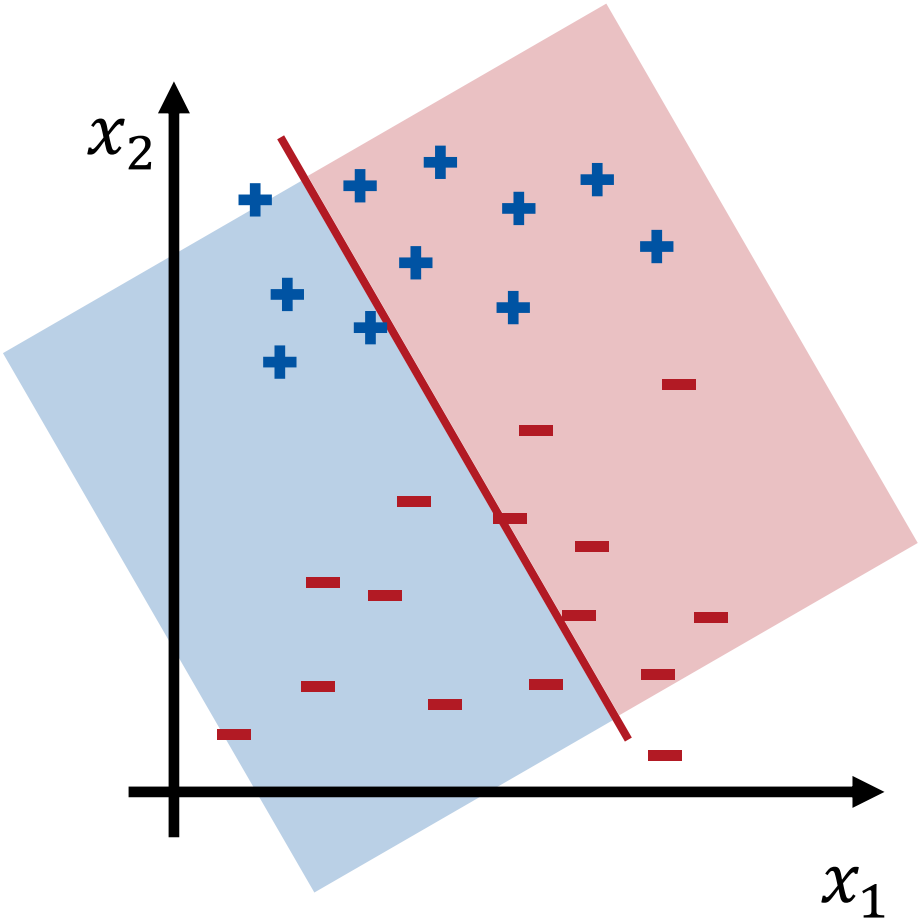
线性分类

- 假设类$\mathcal{H}$：h的集合，$h \in \mathcal{H}$
  - Ex：所有在线的一边的样本标注为+1，线另一边的样本标注-1



线性分类

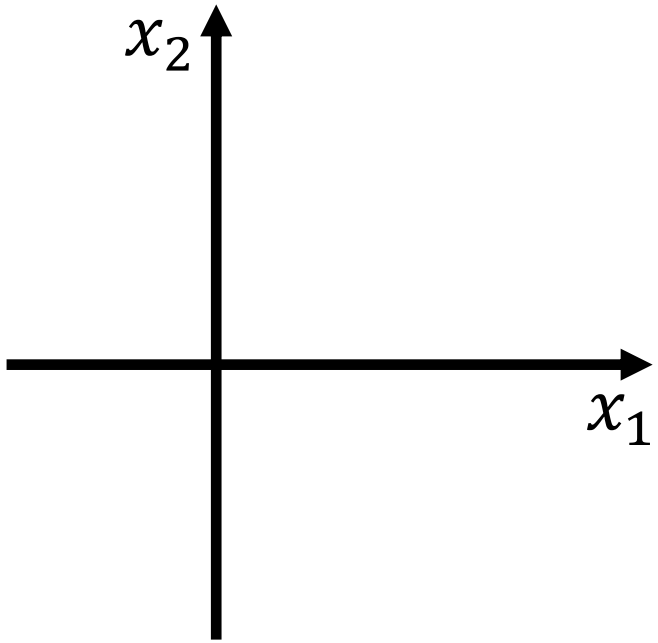
- 假设类$\mathcal{H}$：h的集合，$h \in \mathcal{H}$
  - Ex：所有在线的一边的样本标注为+1，线另一边的样本标注-1

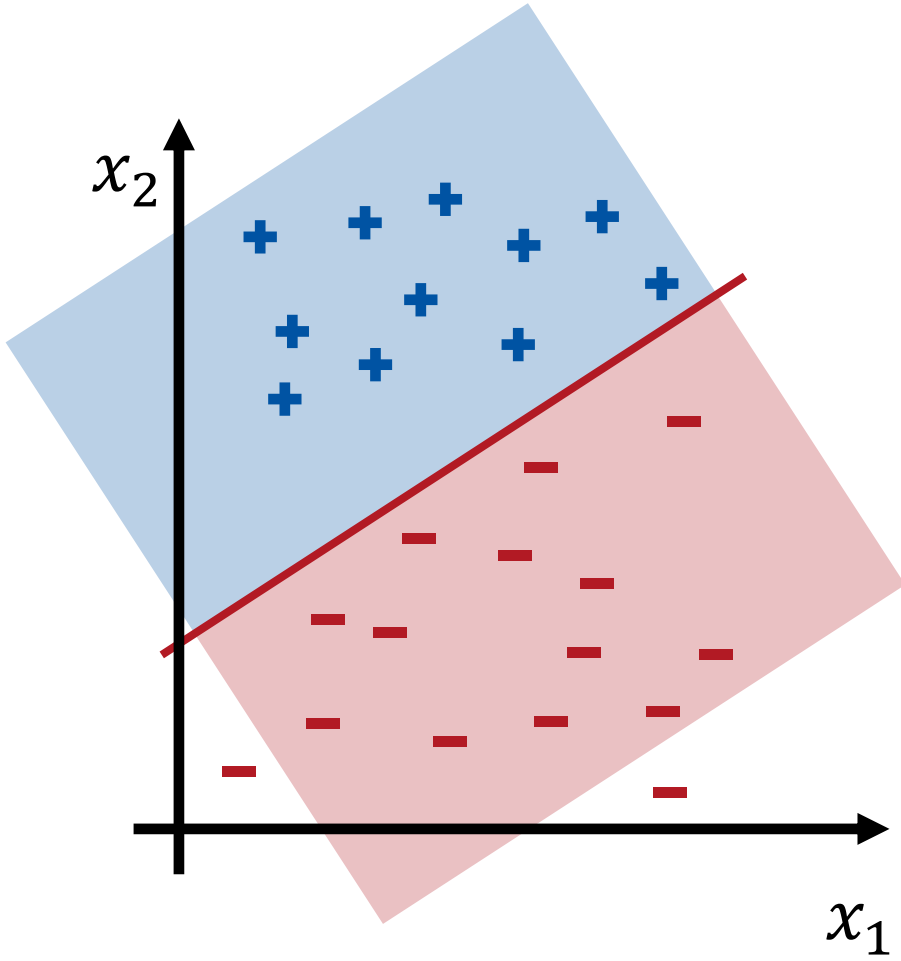


线性分类

- 假设类$\mathcal{H}$：h的集合，$h \in \mathcal{H}$
  - Ex：所有在线的一边的样本标注为+1，线另一边的样本标注-1

符合实际

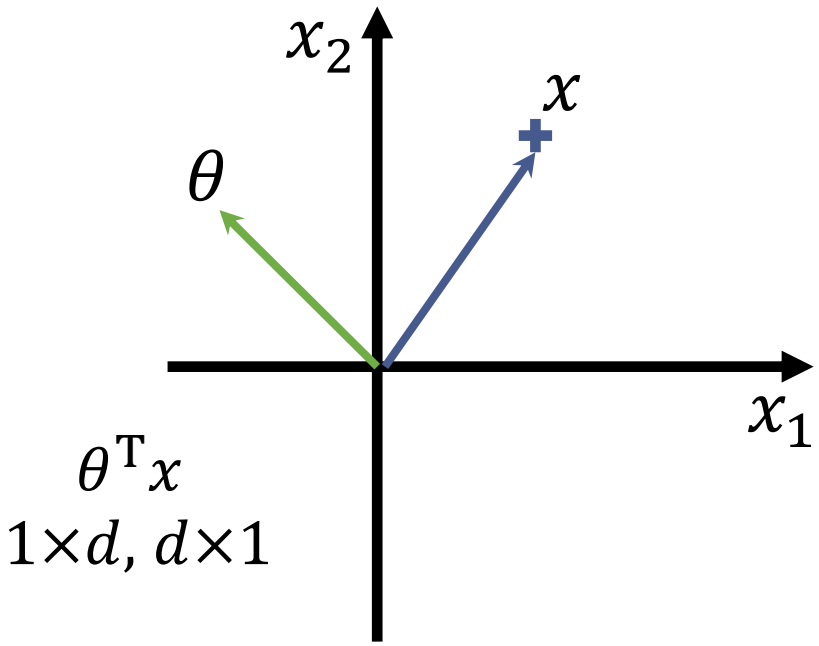


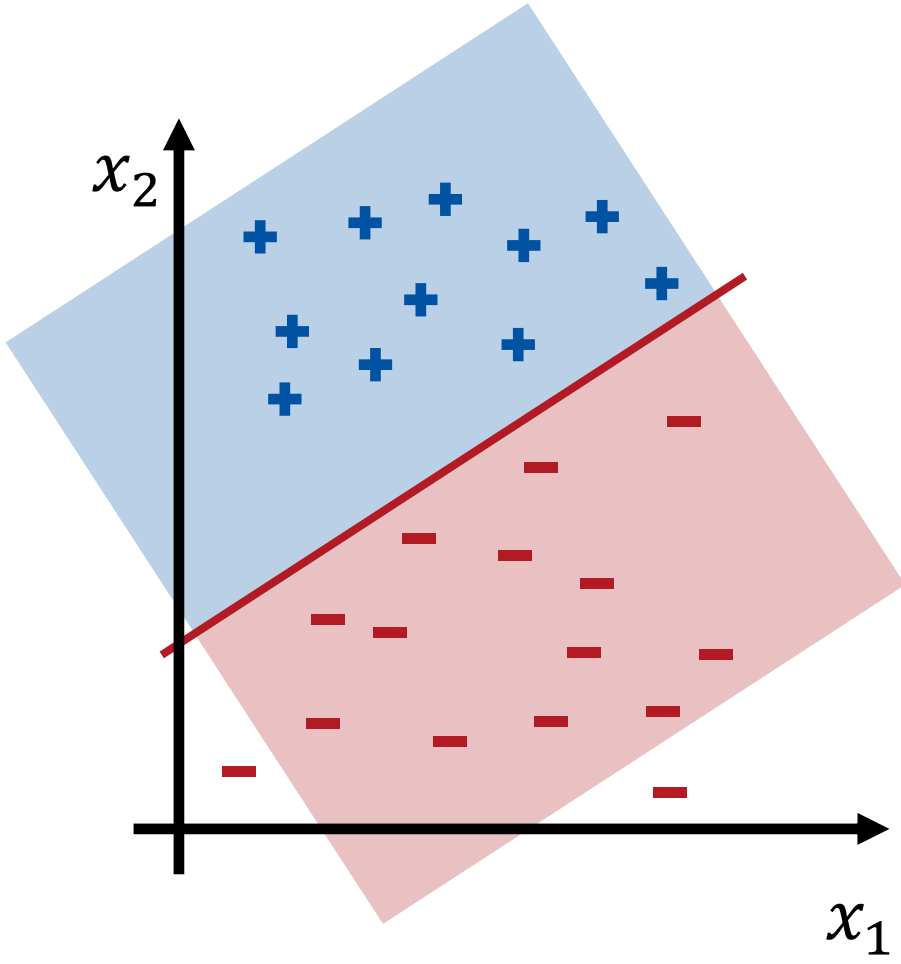


线性分类

- 假设类$\mathcal{H}$：h的集合，$h \in \mathcal{H}$
  - Ex：所有在线的一边的样本标注为+1，线另一边的样本标注-1

符合实际

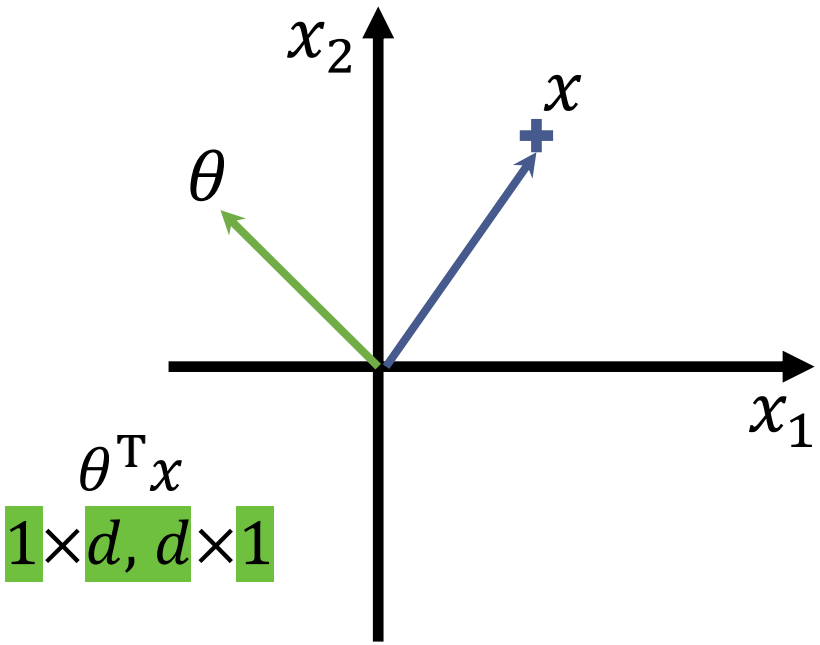


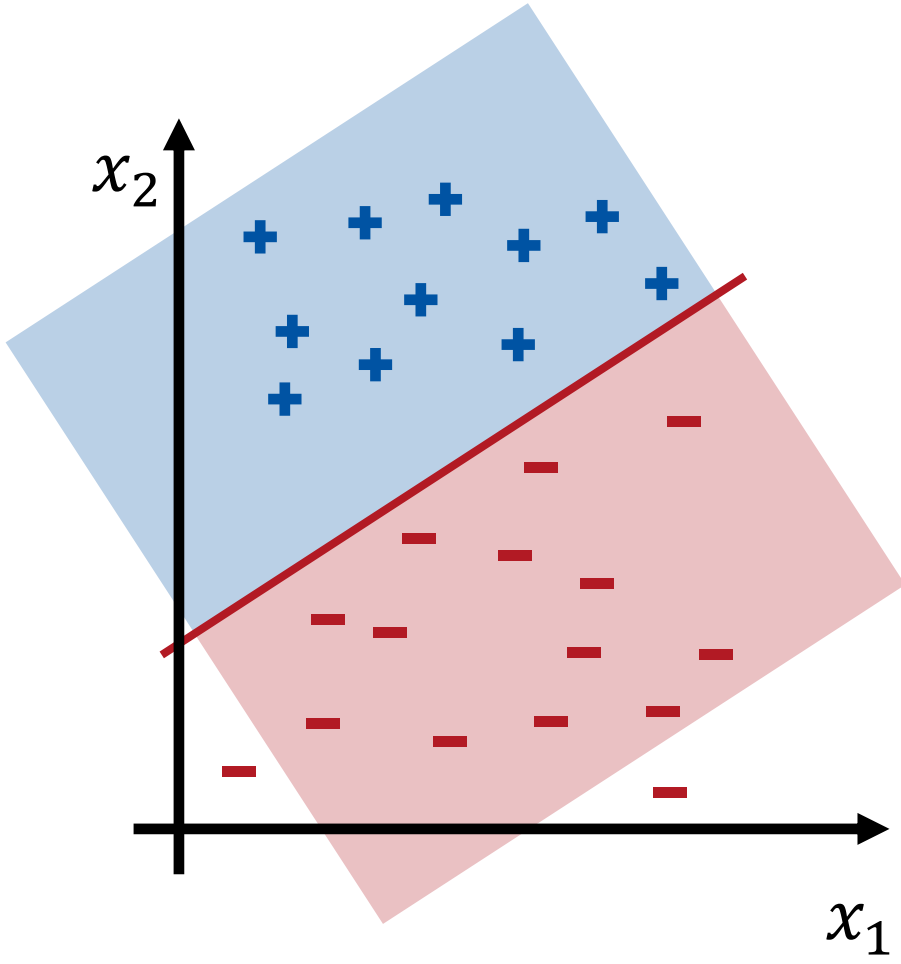


线性分类

- 假设类$\mathcal{H}$：h的集合，$h \in \mathcal{H}$
  - Ex：所有在线的一边的样本标注为+1，线另一边的样本标注-1

符合实际

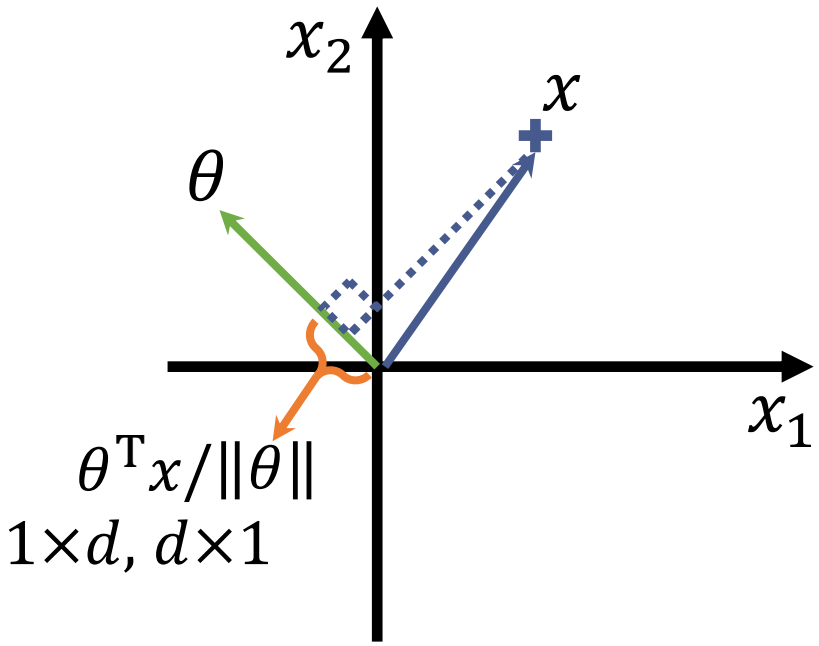


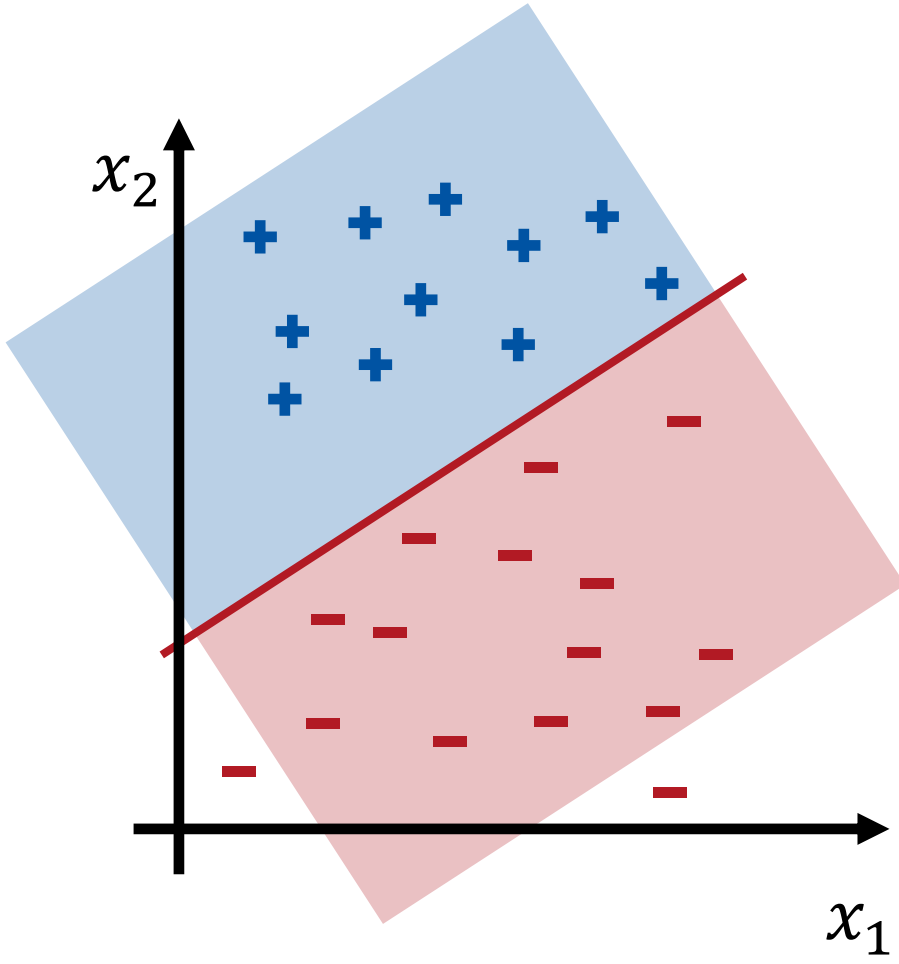


线性分类

- 假设类$\mathcal{H}$：h的集合，$h \in \mathcal{H}$
  - Ex：所有在线的一边的样本标注为+1，线另一边的样本标注-1

符合实际

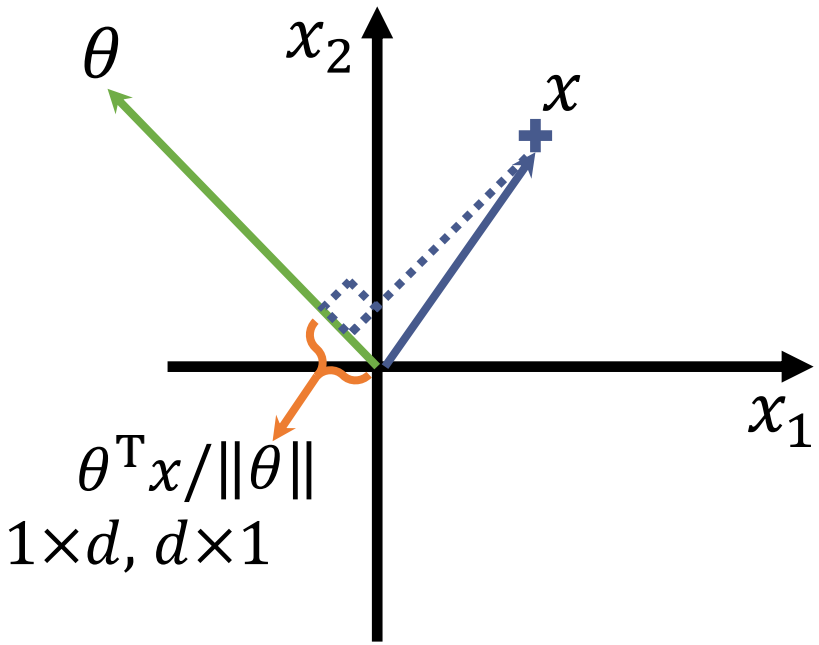


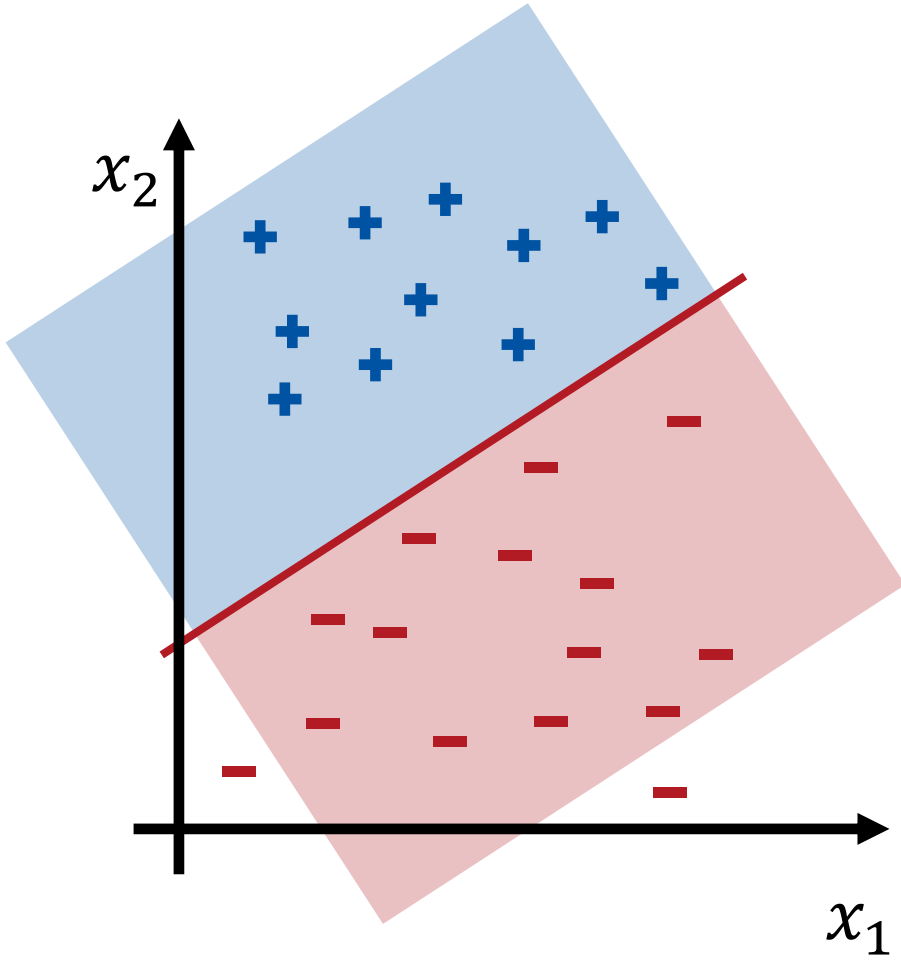


线性分类

- 假设类$\mathcal{H}$：h的集合，$h \in \mathcal{H}$
  - Ex：所有在线的一边的样本标注为+1，线另一边的样本标注-1

符合实际

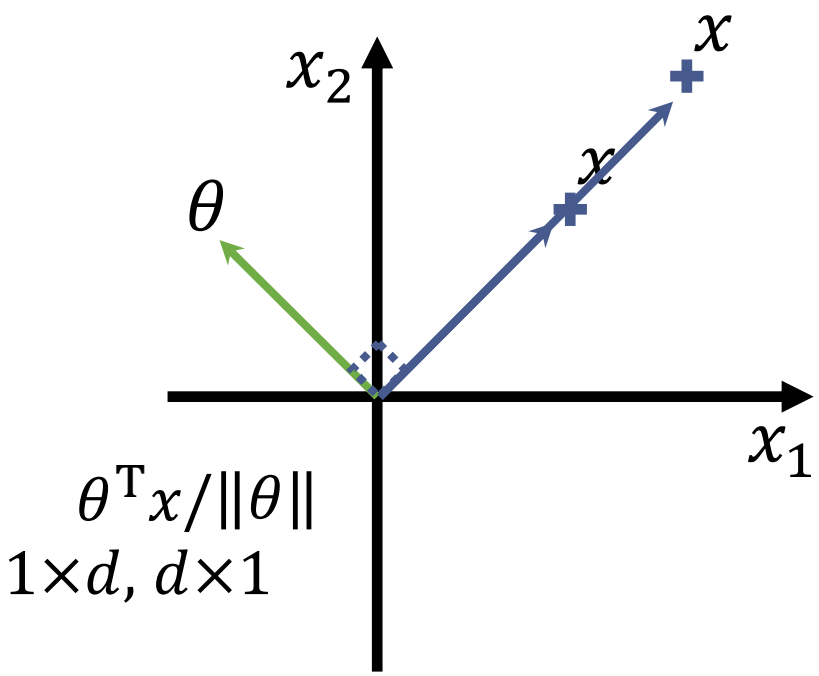


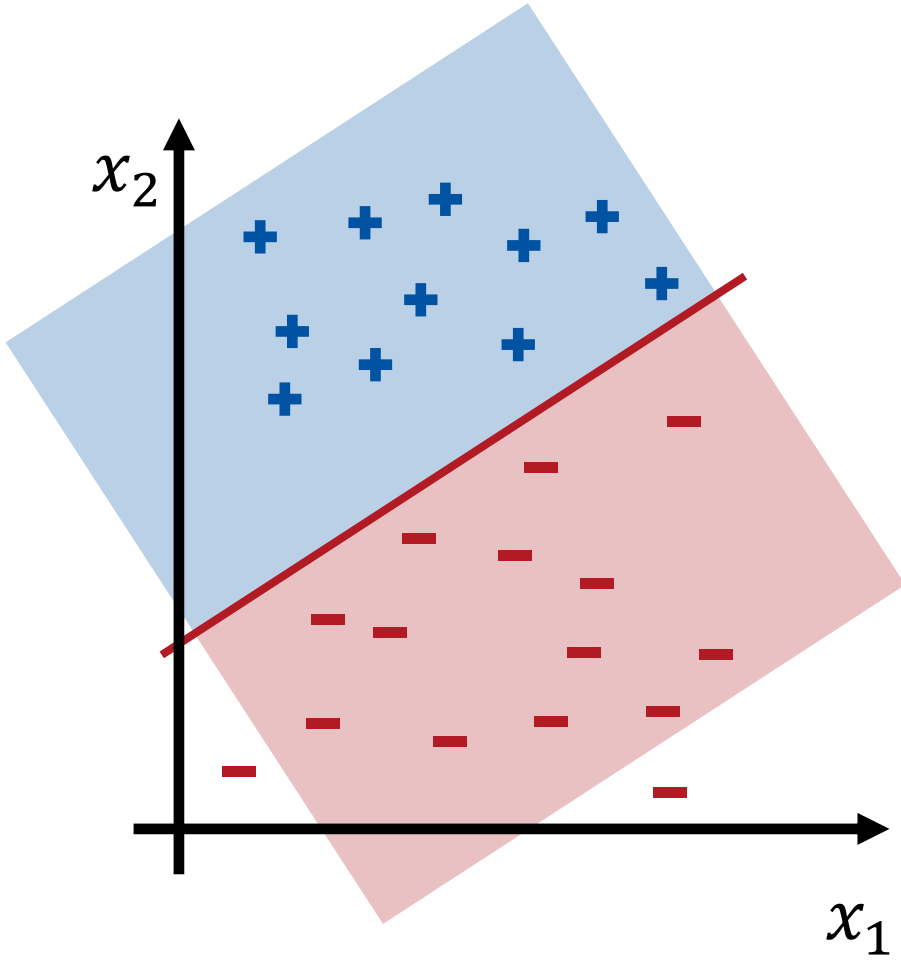


线性分类

- 假设类$\mathcal{H}$：h的集合，$h \in \mathcal{H}$
  - Ex：所有在线的一边的样本标注为+1，线另一边的样本标注-1

符合实际

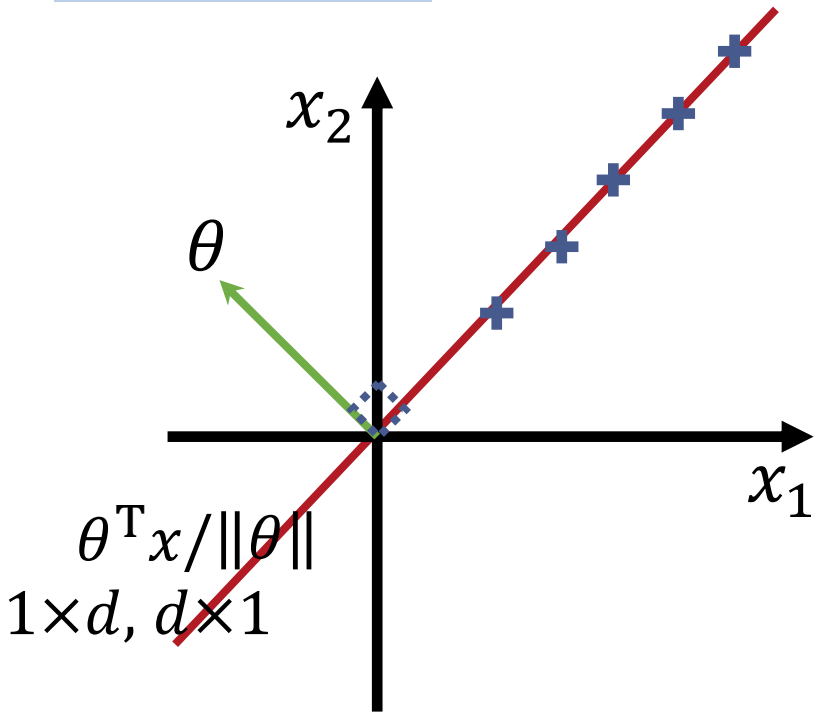


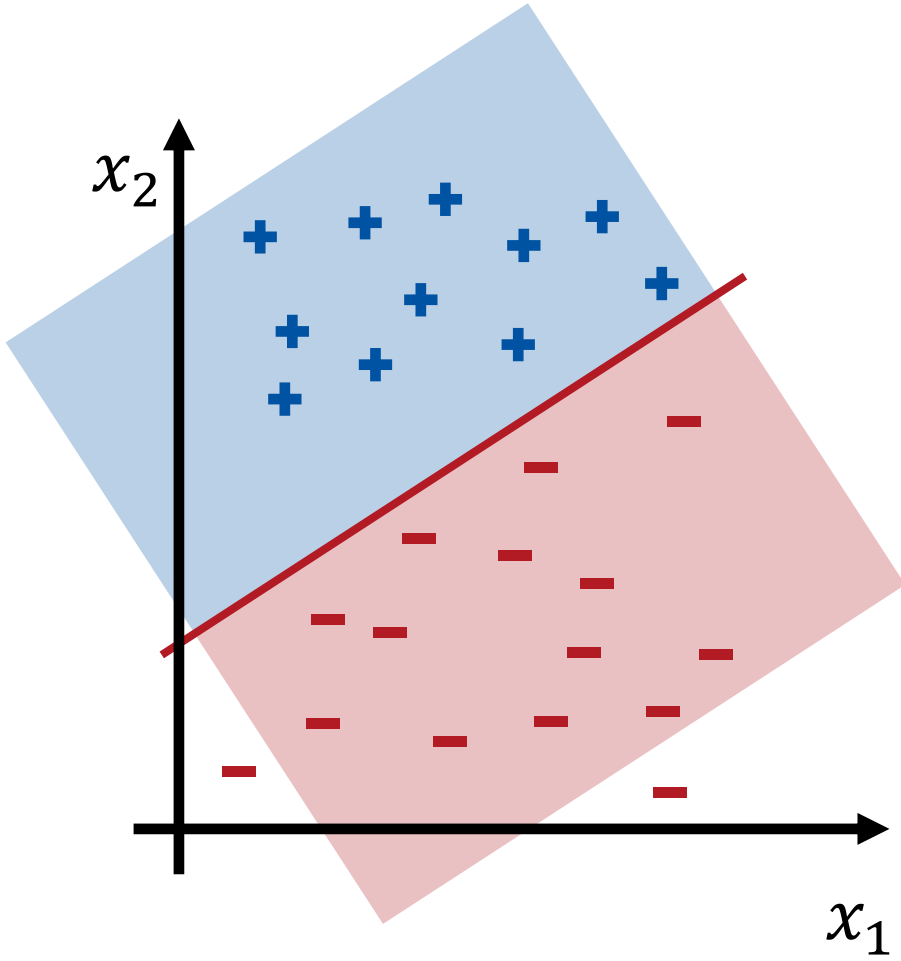


线性分类

- 假设类$\mathcal{H}$：h的集合，$h \in \mathcal{H}$
  - Ex：所有在线的一边的样本标注为+1，线另一边的样本标注-1

符合实际

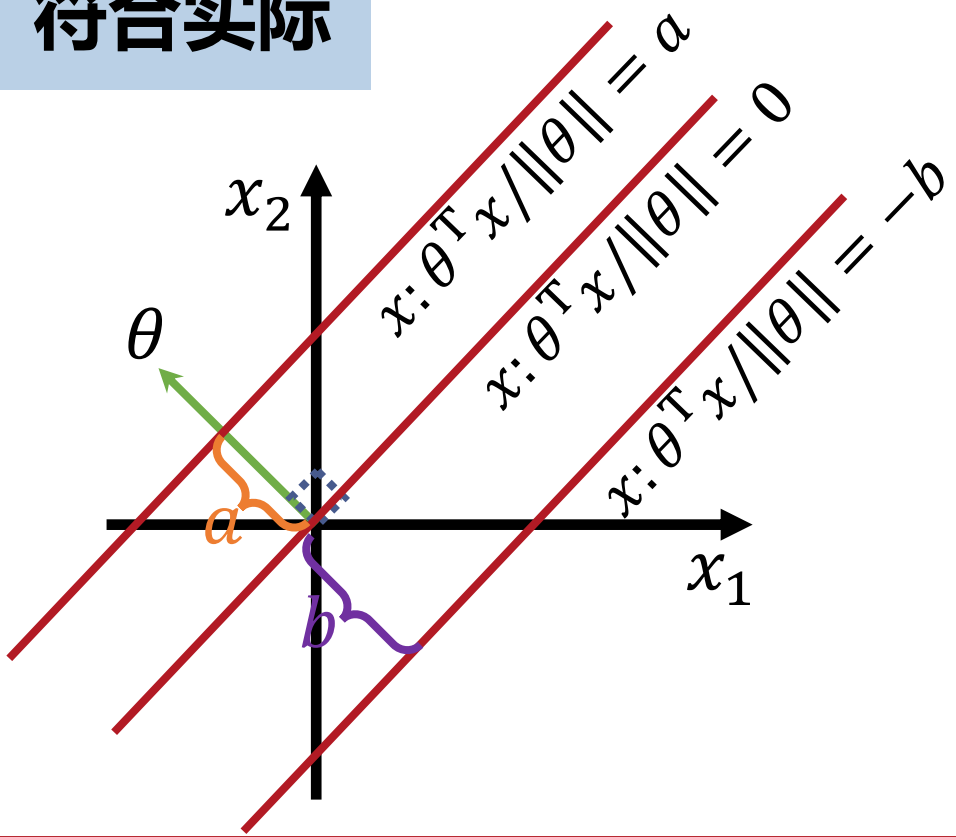


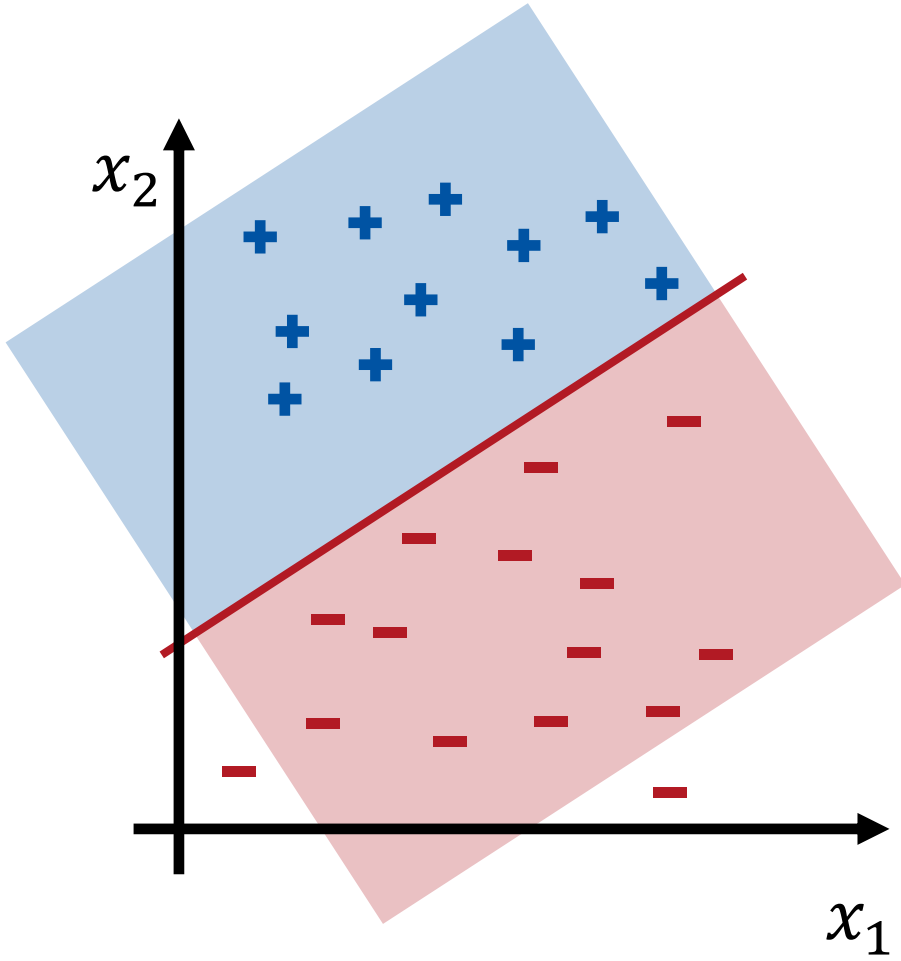


线性分类

- 假设类$\mathcal{H}$：h的集合，$h \in \mathcal{H}$
  - Ex：所有在线的一边的样本标注为+1，线另一边的样本标注-1

符合实际

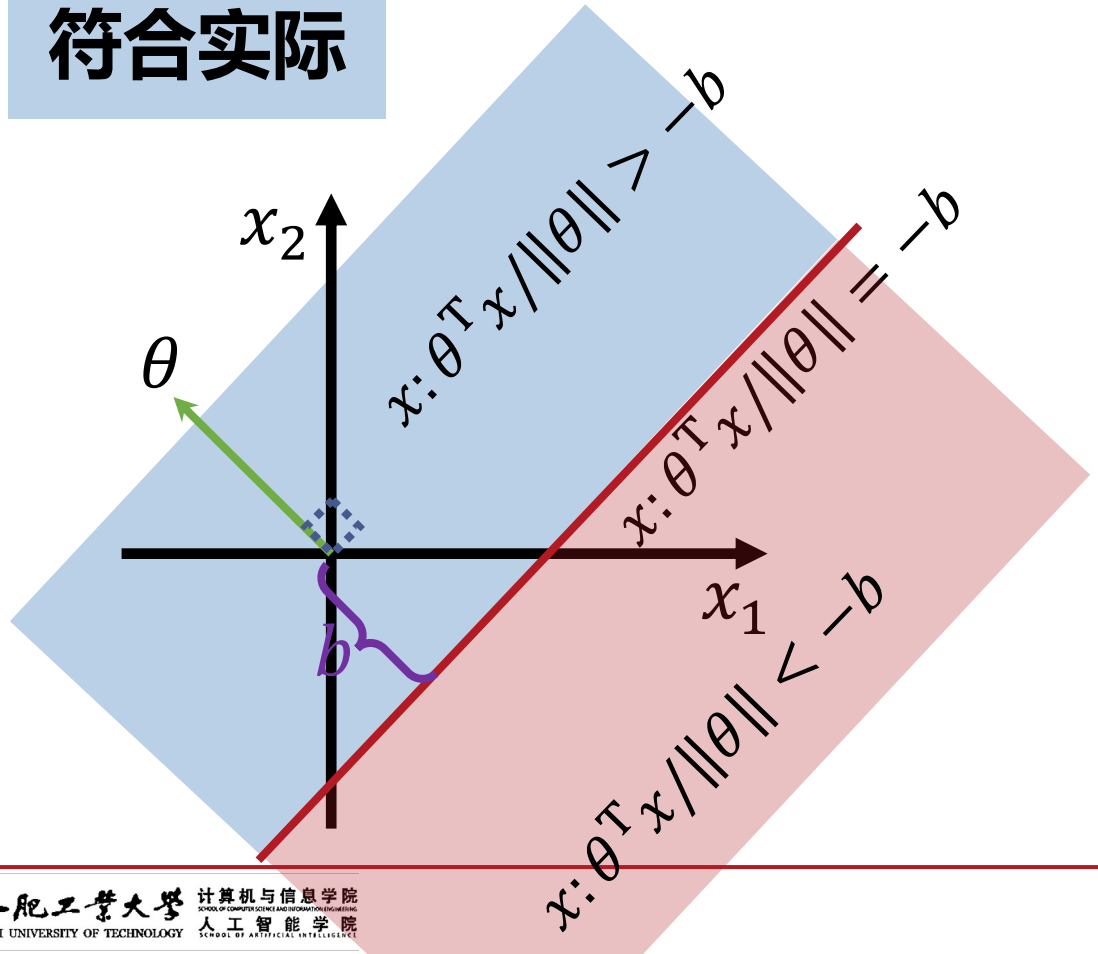


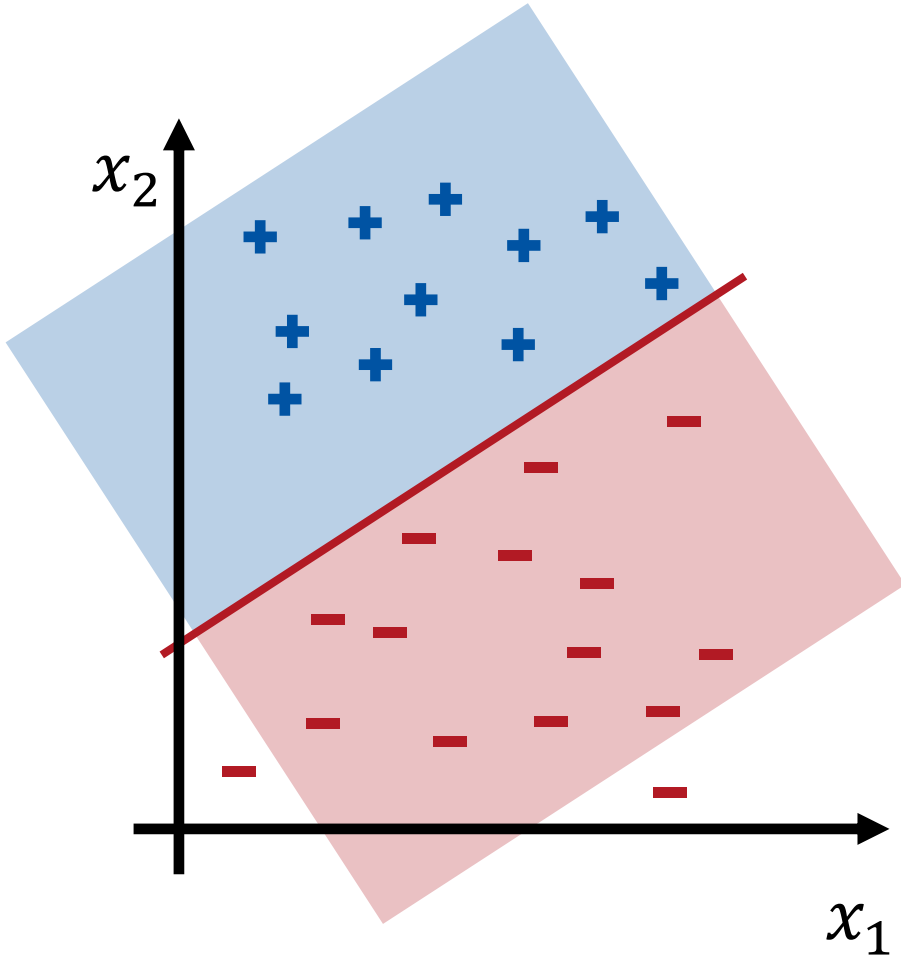


线性分类

- 假设类$\mathcal{H}$：h的集合，$h \in \mathcal{H}$
  - Ex：所有在线的一边的样本标注为+1，线另一边的样本标注-1

符合实际

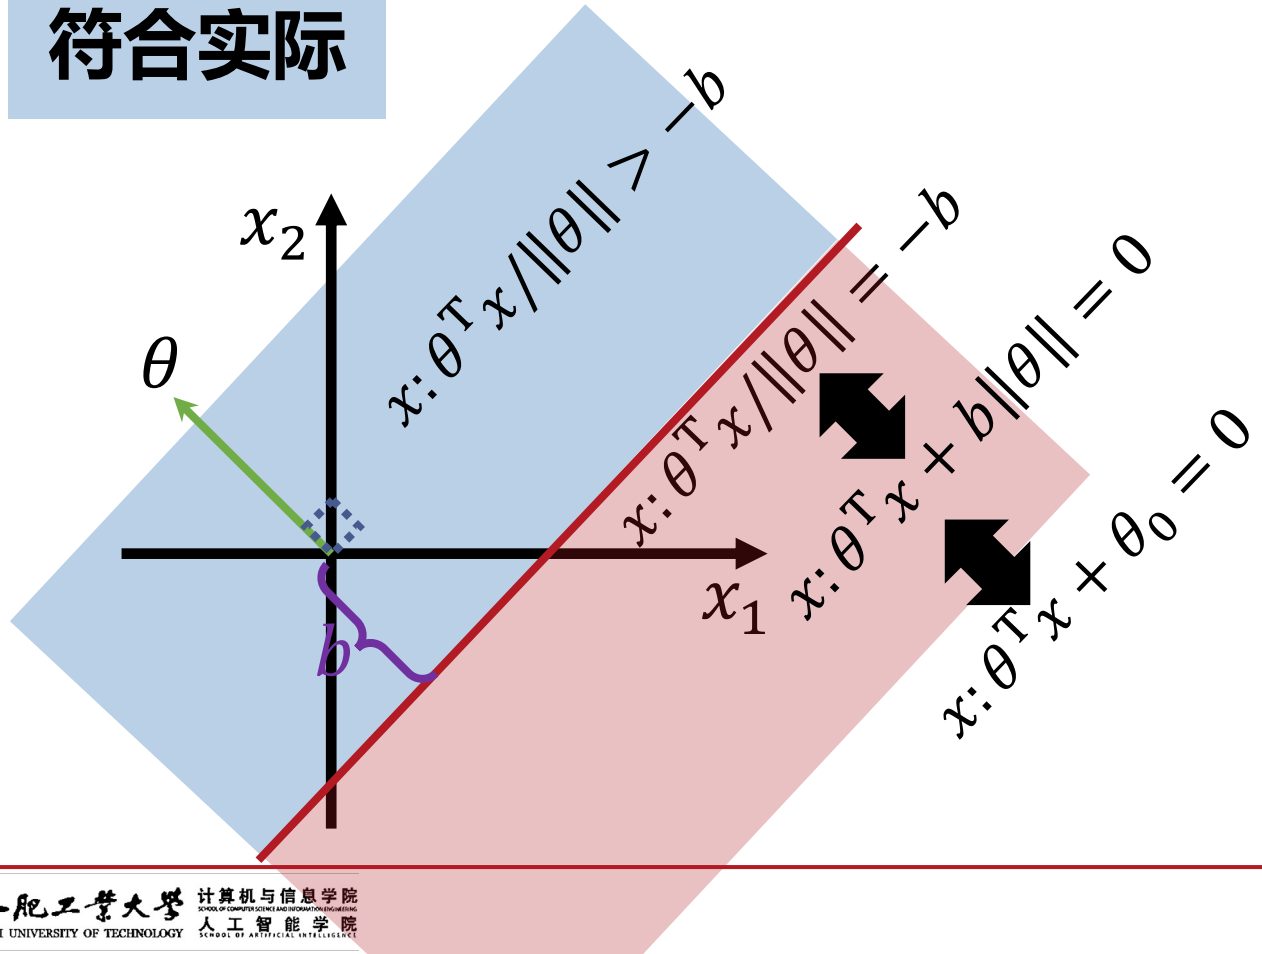


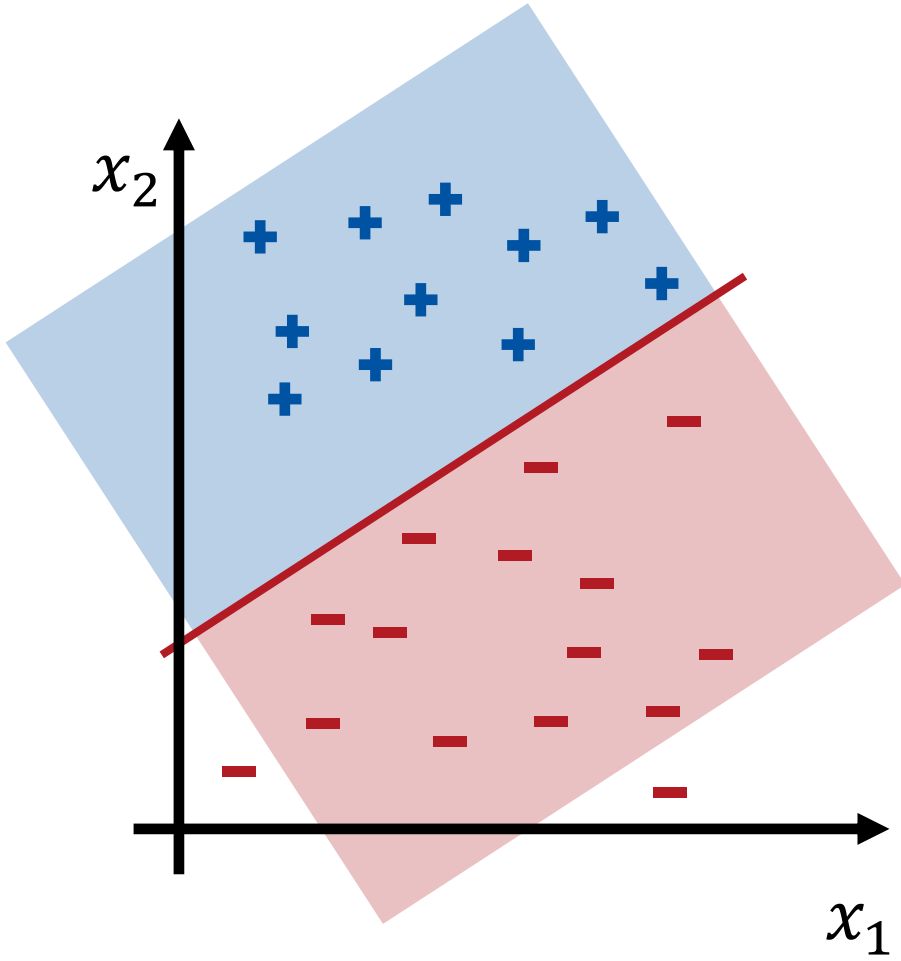


线性分类

- 假设类$\mathcal{H}$：h的集合，$h \in \mathcal{H}$
  - Ex：所有在线的一边的样本标注为+1，线另一边的样本标注-1

符合实际

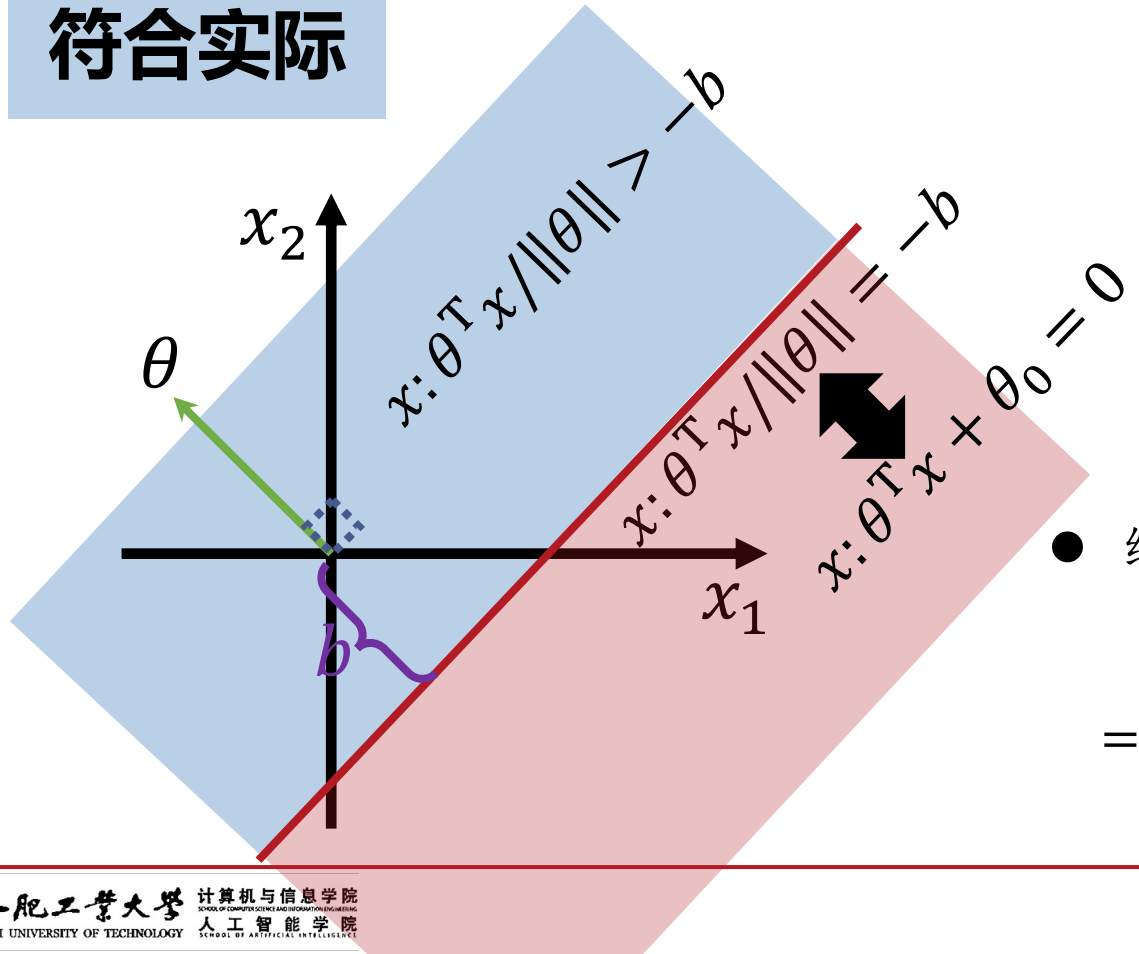


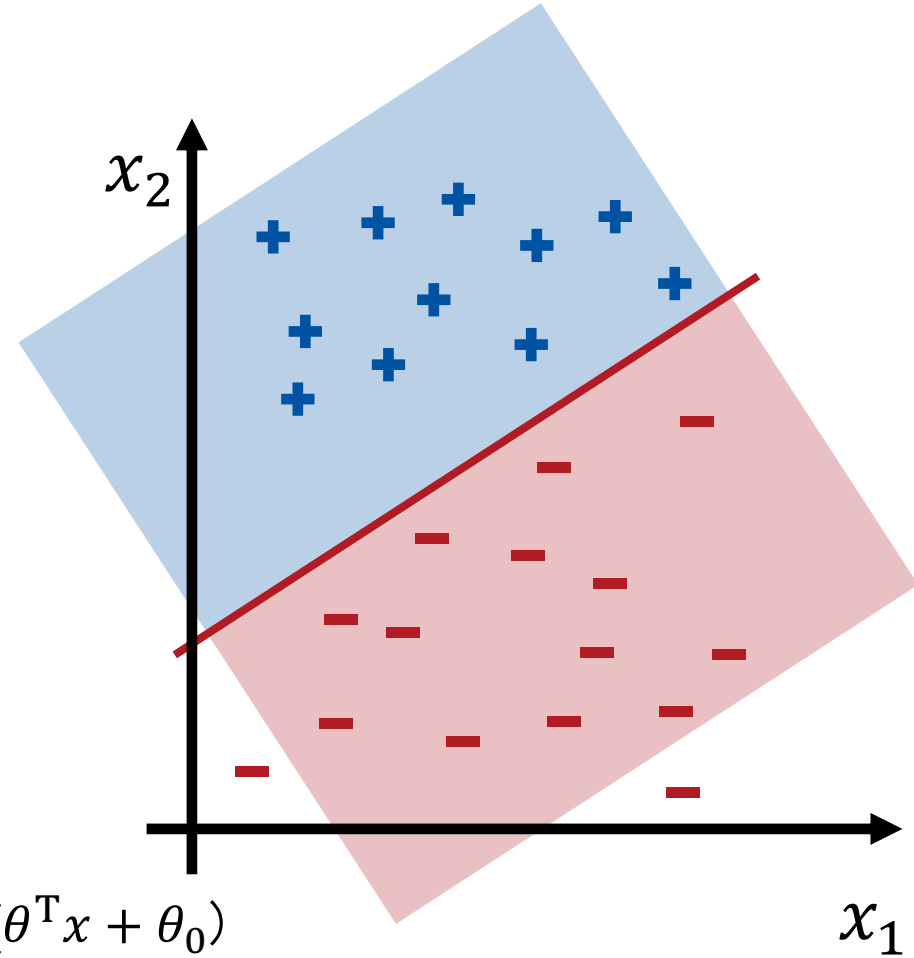


线性分类

- 假设类$\mathcal{H}$：h的集合，$h \in \mathcal{H}$
  - Ex：所有在线的一边的样本标注为+1，线另一边的样本标注-1

符合实际





- 线性分类器

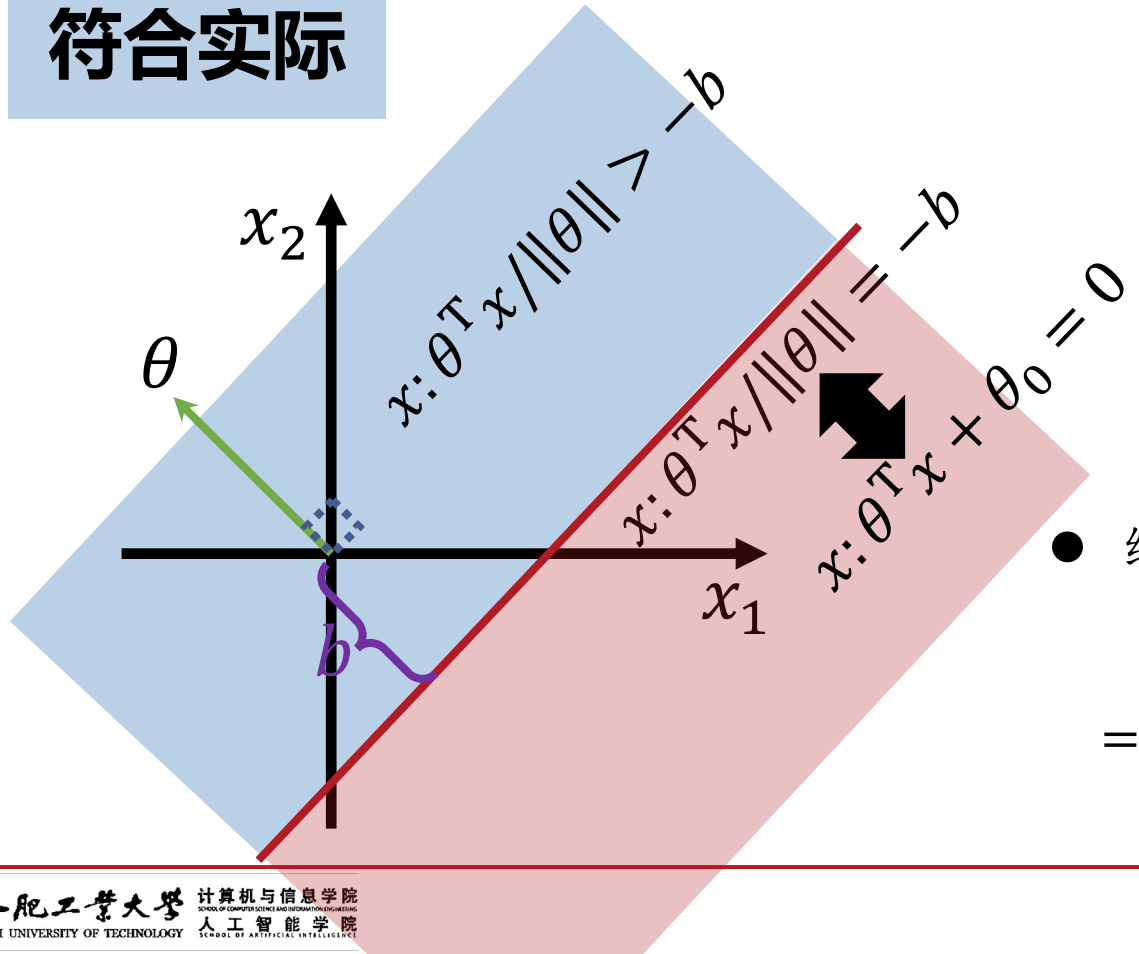
$$h(x) = \text{sign}(\theta^T x + \theta_0)$$

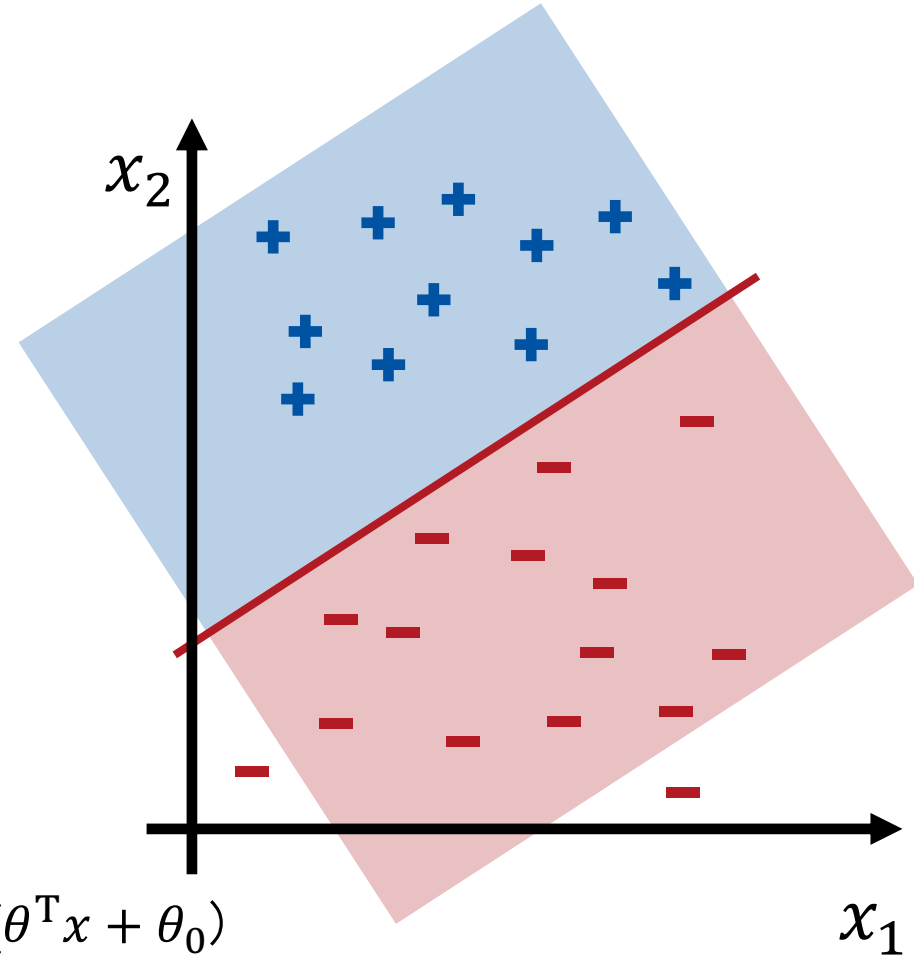
$$= \begin{cases} 1, \text{if } \theta^T x + \theta_0 > 0 \\ 0, \text{if } \theta^T x + \theta_0 \leq 0 \end{cases}$$

线性分类

- 假设类$\mathcal{H}$：h的集合，$h \in \mathcal{H}$
  - Ex：所有在线的一边的样本标注为+1，线另一边的样本标注-1

符合实际





- 线性分类器

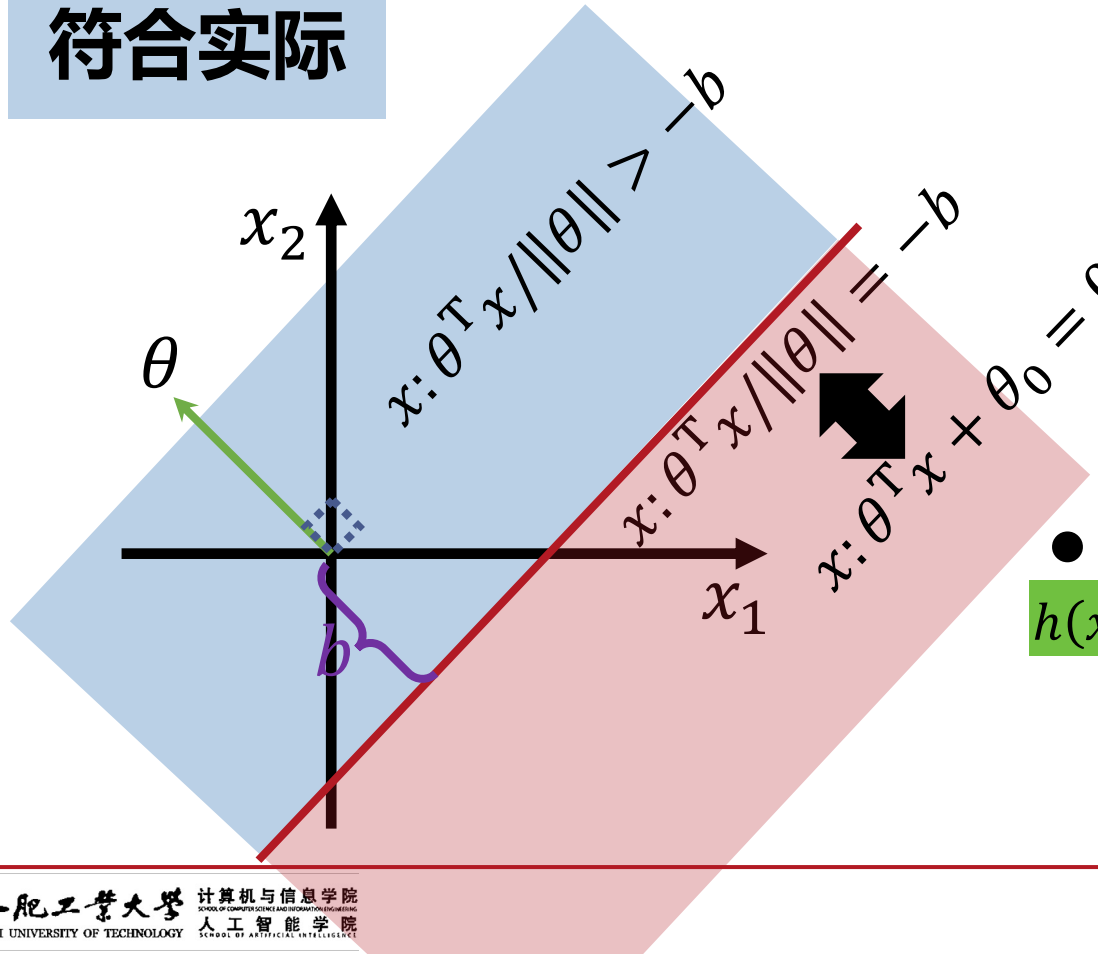
$$h(x) = \text{sign}(\theta^T x + \theta_0)$$

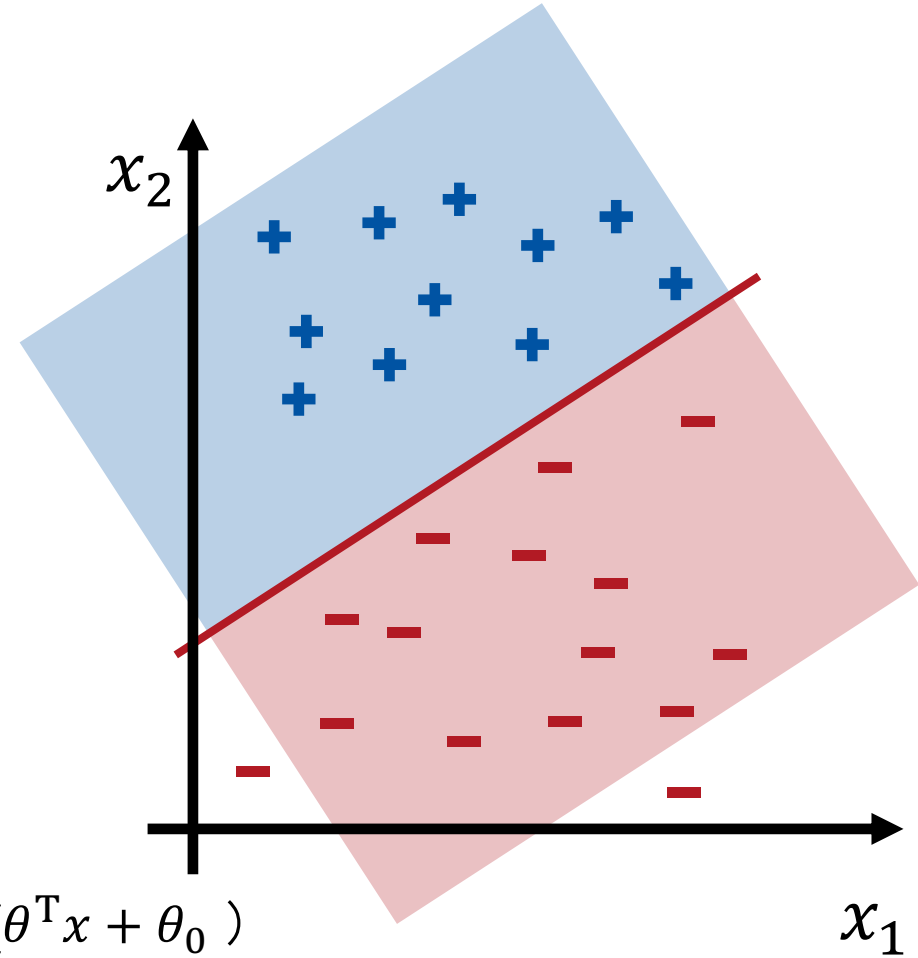
$$= \begin{cases} 1, \text{if } \theta^T x + \theta_0 > 0 \\ 0, \text{if } \theta^T x + \theta_0 \leq 0 \end{cases}$$

线性分类

- 假设类$\mathcal{H}$：h的集合，$h \in \mathcal{H}$
  - Ex：所有在线的一边的样本标注为+1，线另一边的样本标注-1

符合实际





参数

- 线性分类器

$$h(x;\theta,\theta_0) = \text{sign}(\theta^T x + \theta_0)$$

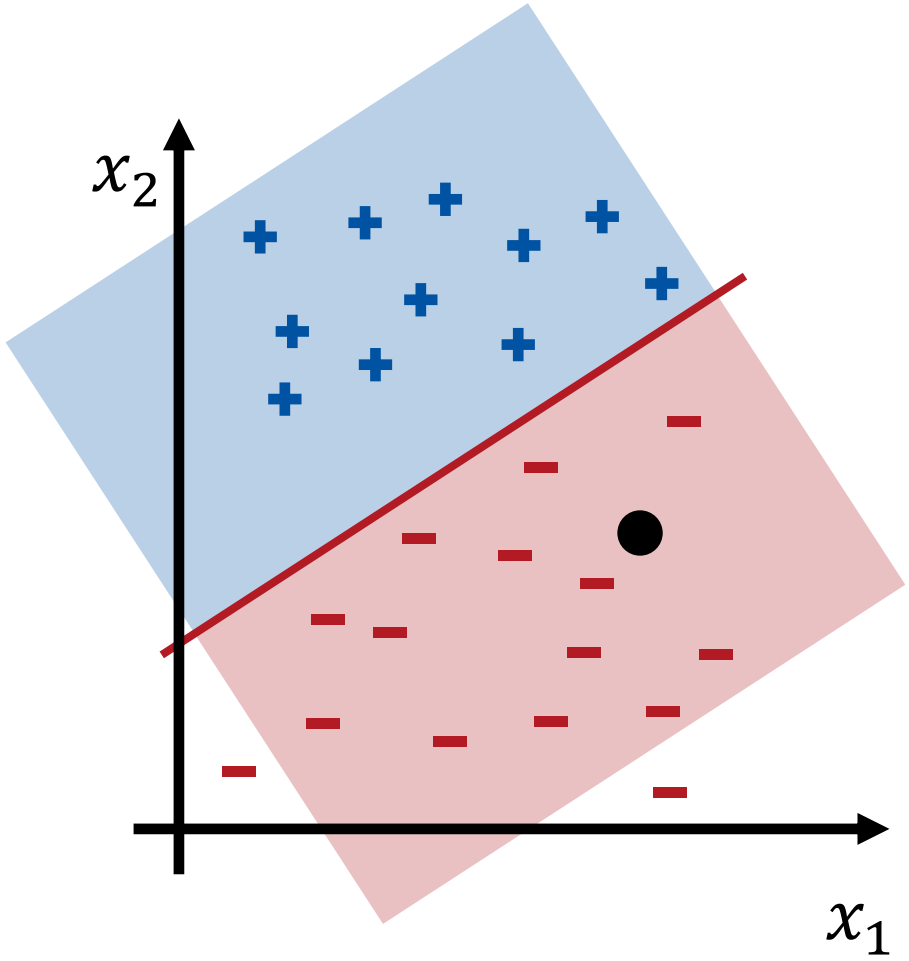
$$= \begin{cases} 1, \text{if } \theta^T x + \theta_0 > 0 \\ 0, \text{if } \theta^T x + \theta_0 \le 0 \end{cases}$$

$\mathcal{H}$ = h的集合

评估分类器

- 能够精准的预测未知数据
- 如何评估单点预测结果？ 损失函数$L(g,a)$

g：预测
a：实际



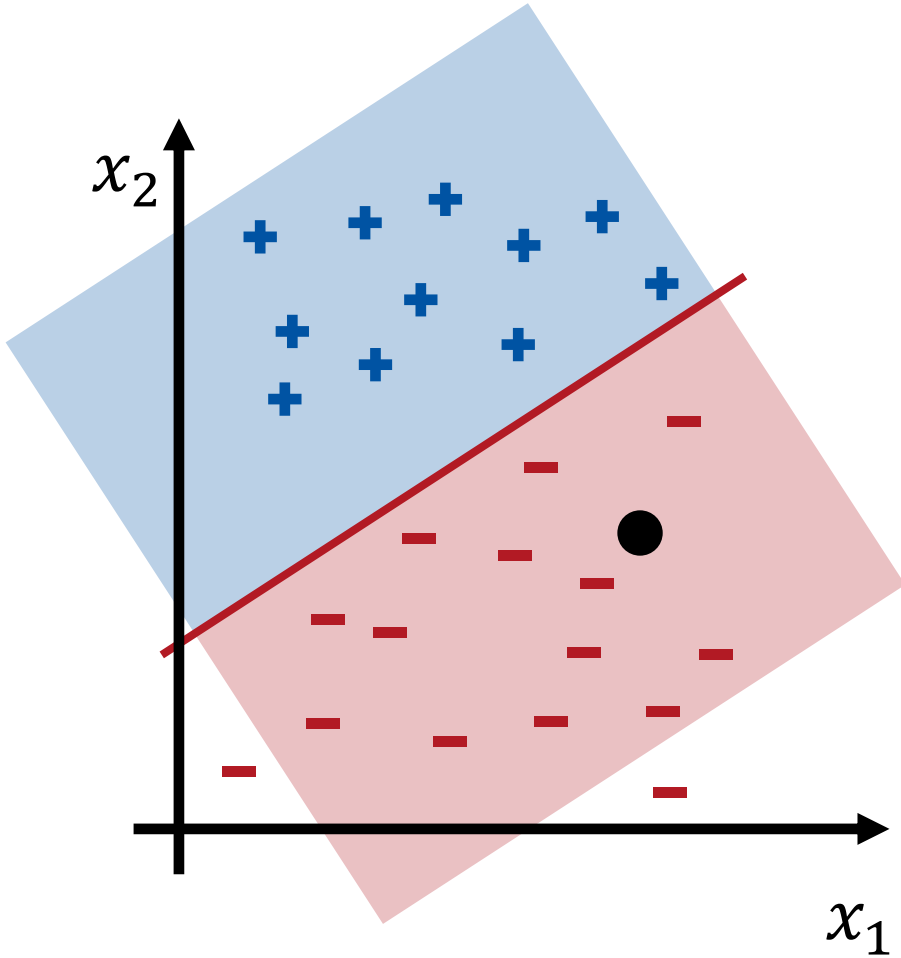
评估分类器

- 能够精准的预测未知数据
- 如何评估单点预测结果？ 损失函数$L(g,a)$

g：预测
a：实际

  - Ex：0-1损失函数

$$L(g,a)=\begin{cases}0, & \text{if } g=a\\ 1, & \text{else}\end{cases}$$



评估分类器

- 能够精准的预测未知数据
- 如何评估单点预测结果？ 损失函数$L(g,a)$

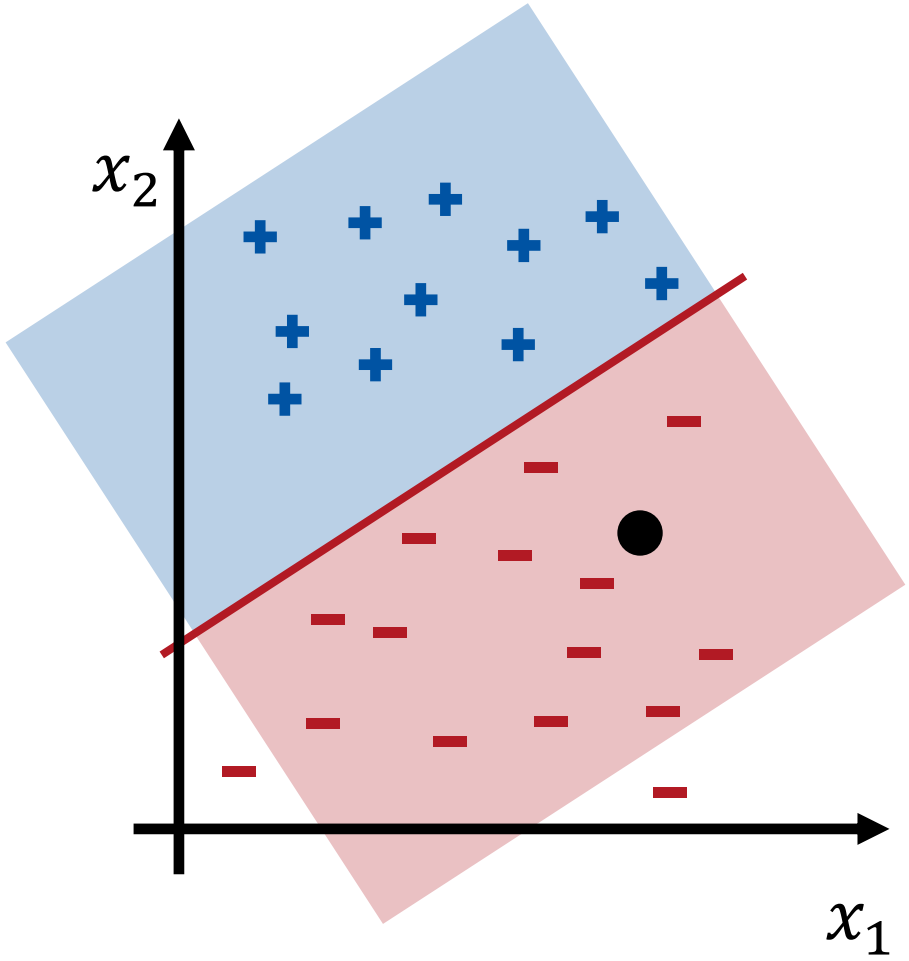
g：预测
a：实际

  - Ex：0-1损失函数

$$L(g,a)=\begin{cases}0, & \text{if } g=a\\ 1, & \text{else}\end{cases}$$

  - Ex：不对称损失函数

$$L(g,a)=\begin{cases}1, & \text{if } g=+1 \text{ and } a=-1\\ 10, & \text{if } g=-1 \text{ and } a=+1\\ 0, & \text{else}\end{cases}$$



评估分类器

- 能够精准的预测未知数据
- 如何评估单点预测结果？ 损失函数$L(g,a)$

g：预测
a：实际

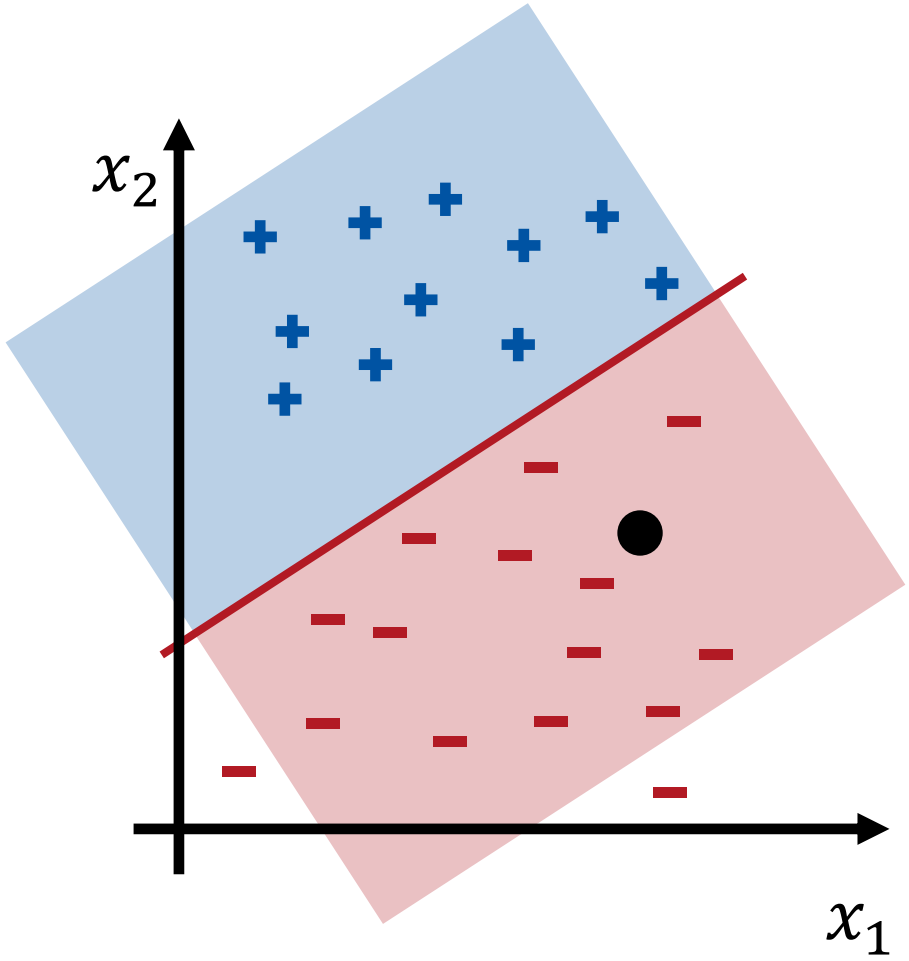
  - Ex：0-1损失函数

$$L(g,a)=\begin{cases}0, & \text{if } g=a\\ 1, & \text{else}\end{cases}$$

  - Ex：不对称损失函数

$$L(g,a)=\begin{cases}1, & \text{if } g=+1 \text{ and } a=-1\\ 10, & \text{if } g=-1 \text{ and } a=+1\\ 0, & \text{else}\end{cases}$$

- 测试误差（m个新样本）：$\mathcal{E}(h)=\frac{1}{m}\sum_{i=n+1}^{n+m}L(h(x^{(i)}),y^{(i)})$
- 训练误差：$\mathcal{E}_n(h)=\frac{1}{n}\sum_{i=1}^{n}L(h(x^{(i)}),y^{(i)})$



评估分类器

- 能够精准的预测未知数据
- 如何评估单点预测结果？ 损失函数$L(g,a)$

g：预测
a：实际

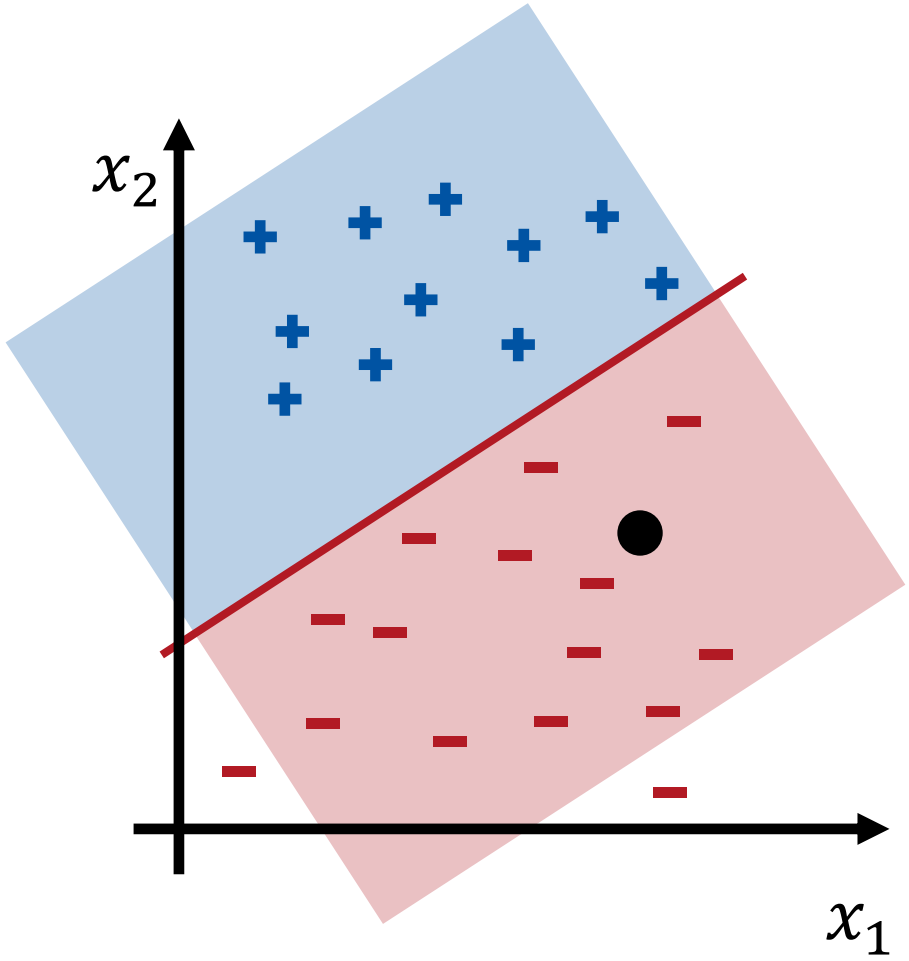
  - Ex：0-1损失函数

$$L(g,a)=\begin{cases}0, & \text{if } g=a\\ 1, & \text{else}\end{cases}$$

  - Ex：不对称损失函数

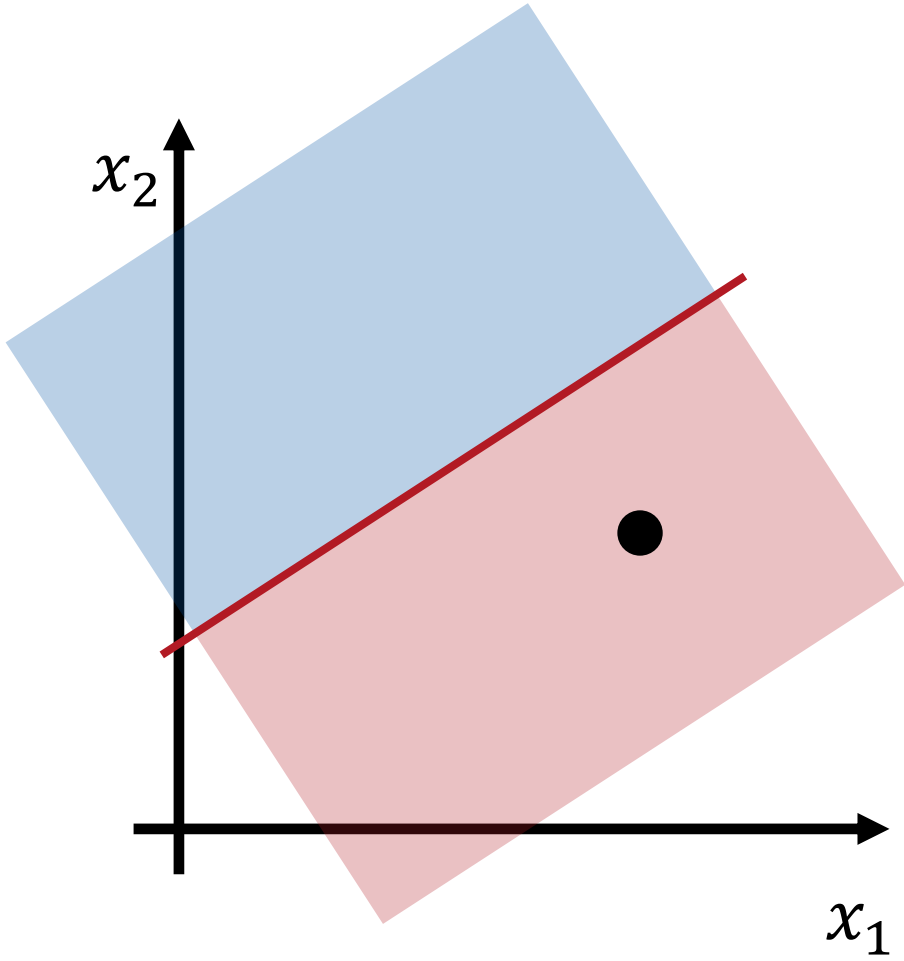
$$L(g,a)=\begin{cases}1, & \text{if } g=+1 \text{ and } a=-1\\ 10, & \text{if } g=-1 \text{ and } a=+1\\ 0, & \text{else}\end{cases}$$

- 测试误差（m个新样本）：$\mathcal{E}(h)=\frac{1}{m}\sum_{i=n+1}^{n+m}L(h(x^{(i)}),y^{(i)})$
- 训练误差：$\mathcal{E}_n(h)=\frac{1}{n}\sum_{i=1}^{n}L(h(x^{(i)}),y^{(i)})$
- 假设评估： h优于$\tilde{h}$当$\mathcal{E}_n(h)<\mathcal{E}_n(\tilde{h})$



学习分类器

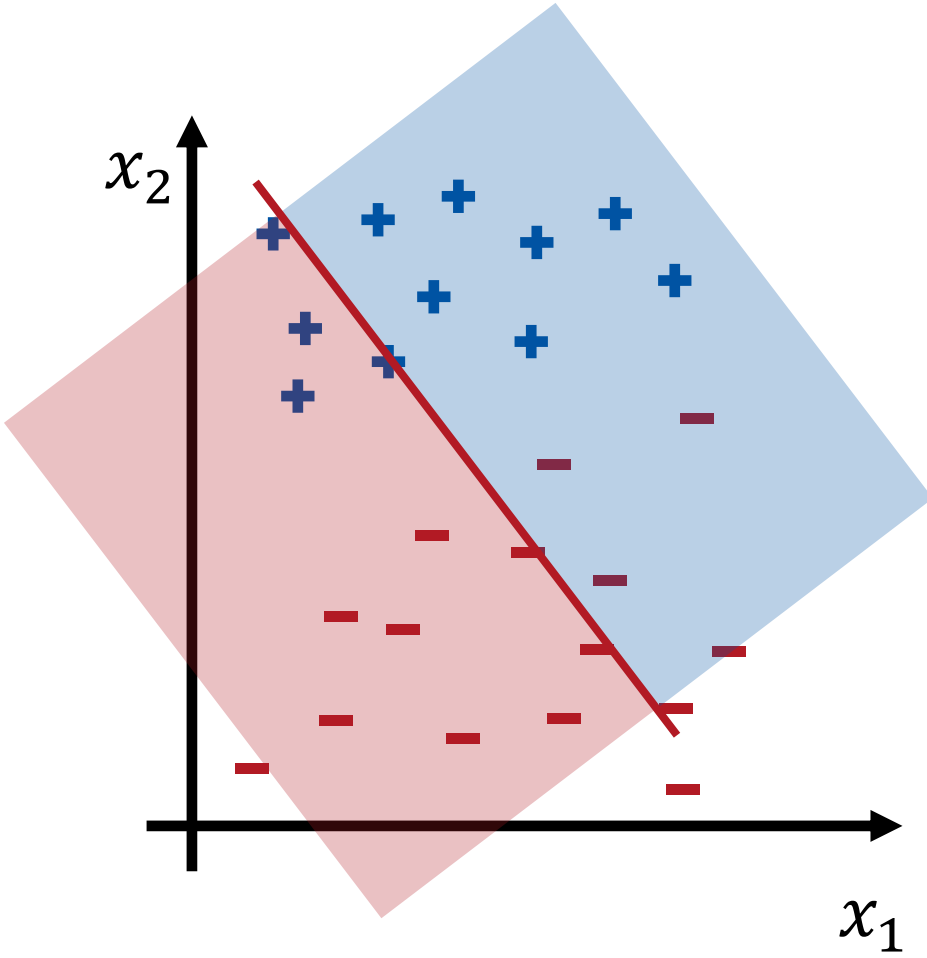
- 有数据；有假设类
- 目标：选择一个好的分类器
  - 回顾：$x \rightarrow h \rightarrow y$



学习分类器

- 有数据；有假设类
- 目标：选择一个好的分类器
  - 回顾：$x \rightarrow h \rightarrow y$
  - 学习算法：

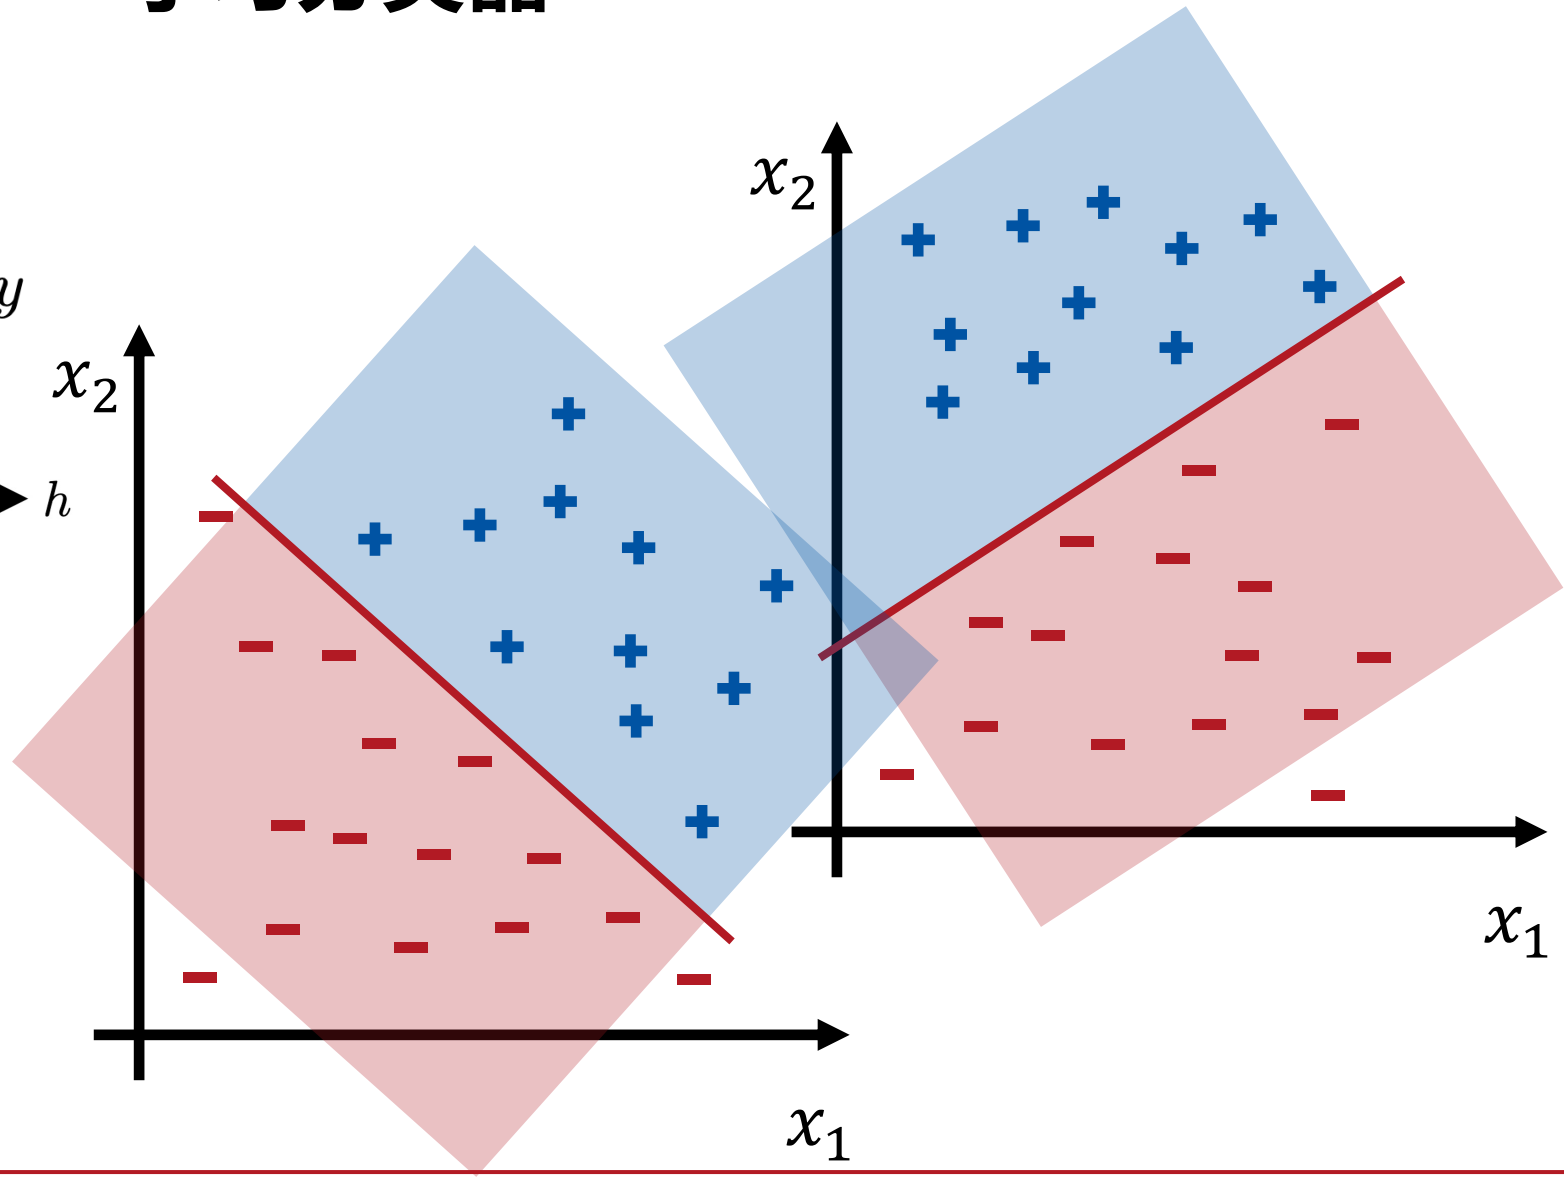
$$\mathcal{D}_n \rightarrow \boxed{\text{learning algorithm}} \rightarrow h$$



学习分类器

- 有数据；有假设类
- 目标：选择一个好的分类器
  - 回顾：$x \rightarrow h \rightarrow y$
  - 学习算法：

$\mathcal{D}_n \rightarrow$ learning algorithm $\rightarrow h$



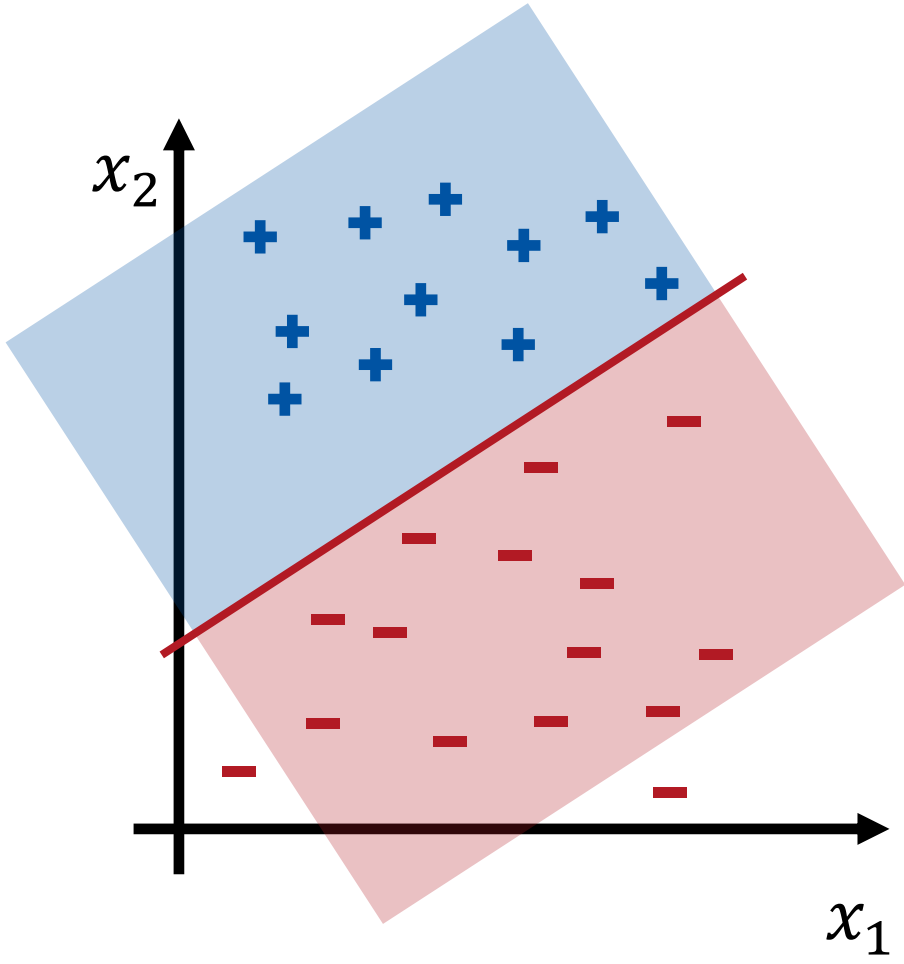
学习分类器

- 有数据；有假设类
- 目标：选择一个好的分类器
  - 回顾：$x \rightarrow h \rightarrow y$
  - 学习算法：

$\mathcal{D}_n \rightarrow$ learning algorithm $\rightarrow h$

- 伪代码

```
1. for j=1, ... , 1000000
2.     randomly sample (θ^(j), θ_0^(j))
3.     set h^(j)(x) = h(x; θ^(j), θ_0^(j))
4. Ex_learning_alg(D_n; k < 100000)
5.     set j* = argmin_{j∈{1,...,k}} E_n(h^(j))
6.     return h^(j*)
```



学习分类器

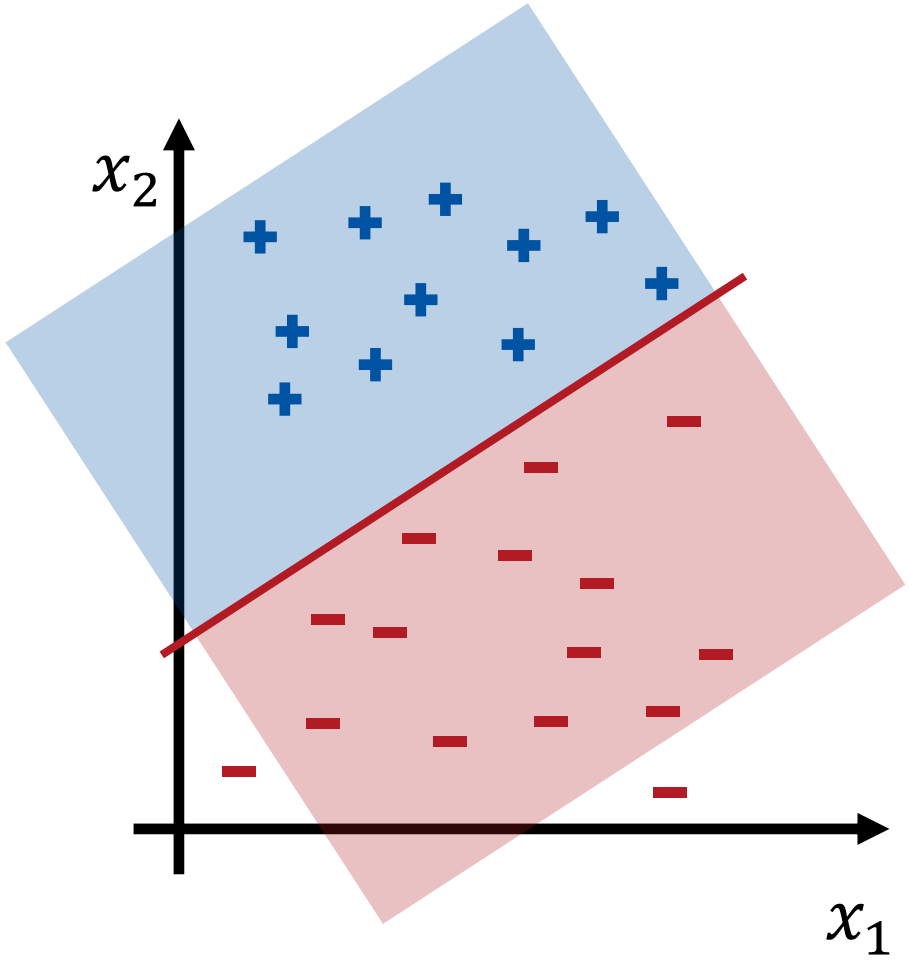
- 有数据；有假设类
- 目标：选择一个好的分类器
  - 回顾：$x \rightarrow h \rightarrow y$
  - 学习算法：

$\mathcal{D}_n \rightarrow$ learning algorithm $\rightarrow h$

- 伪代码

```
1. for j=1, ... , 1000000
2.     randomly sample (θ^(j), θ_0^(j))
3.     set h^(j)(x) = h(x; θ^(j), θ_0^(j))
4. Ex_learning_alg(D_n; k ← 100000)
5.     set j* = argmin_{j∈{1,...,k}} ε_n(h^(j))
6.     return h^(j*)
```

超参数



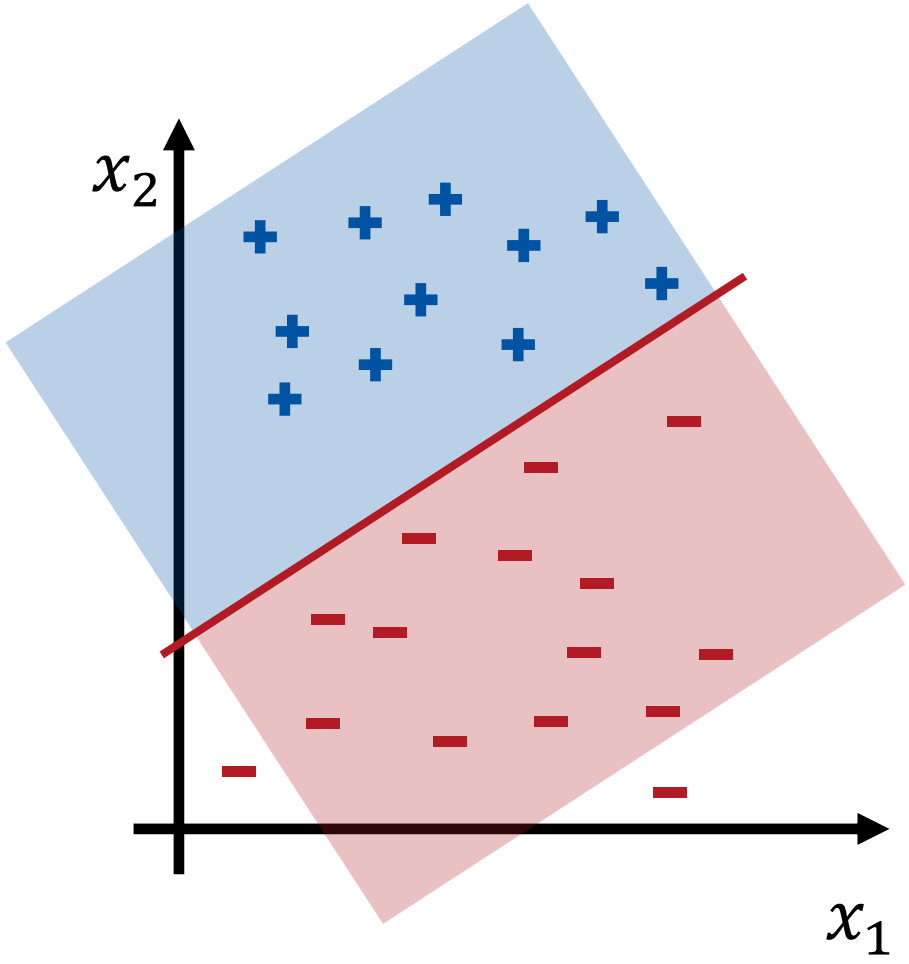
学习分类器

- 有数据；有假设类
- 目标：选择一个好的分类器
  - 回顾：$x \rightarrow h \rightarrow y$
  - 学习算法：

$\mathcal{D}_n \rightarrow$ learning algorithm $\rightarrow h$

- 伪代码

```
1. for j=1, ... , 1000000
2.     randomly sample (θ^(j), θ_0^(j))
3.     set h^(j)(x) = h(x; θ^(j), θ_0^(j))
4. Ex_learning_alg(D_n; k < 100000)
5.     set j* = argmin_{j∈{1,...,k}} E_n(h^(j))
6.     return h^(j*)
```



- Ex_learning_alg($\mathcal{D}_n$;1)相比于Ex_learning_alg($\mathcal{D}_n$;2)的训练误差如何？